

Modismi, polisemia e collocazioni lessicali in vari modelli AI

Autore: Luca A. Bianchini

Pubblicato il 10 settembre 2026

TL; DR

1. Analisi di 127 LLM (111 open-weight + 16 commerciali) sul gioco “La Ghigliottina”, riadattato in inglese con un dataset originale di 30 item.
2. Nessun modello coincide sistematicamente con la soluzione dell'autore; il migliore open-weight (stepfun/step-3.5-flash, 71.1%) e il migliore commerciale (x-ai/grok-4.6, 76.7%) restano lontani dal 100% e non sono statisticamente distinguibili dagli altri modelli di vertice del proprio gruppo.
3. Includendo i sinonimi validati a mano, la correttezza estesa sale fino all'80.0% (*bytedance-seed/seed-2-1-turbo*): parte della distanza dalla soluzione è un limite delle metriche automatiche, non un vero fallimento del modello.
4. In almeno tre item (supermarket/checkout, emotion/stress, watching/watch) la risposta convergente dei modelli è risultata più coerente della soluzione originale dell'autore.
5. La temperatura (0.0/0.3/0.7) non ha un effetto aggregato significativo sull'accuratezza, il ranking dei modelli resta stabile tra le temperature.
6. La dimensione del modello correla fortemente con l'accuratezza ($\rho=0.756/0.690$) ma non è l'unico fattore: *gpt-oss:20b* (solo 3.61B parametri attivi, MoE) resta tra i migliori.
7. La rarità lessicale (Zipf) non spiega la difficoltà in generale ($\rho=0.246$, non significativo); resta un fattore reale solo per il caso isolato di petrichor.
8. guillo_10 (PC) è l'item più difficile in assoluto (0.000 su 193 tentativi). Nessun modello sceglie l'acronimo anche notandolo esplicitamente nel ragionamento.
9. *starcoder2:15b-instruct*, in 46/90 risposte, risponde correttamente e poi continua a generare codice Python estraneo fino al limite di token.
10. *deepseek-r1:14b* oscilla ripetutamente tra MOUSE (corretto) e BEAST, chiudendo arbitrariamente su BEAST. Conoscenza proposizionale corretta, assente il controllo procedurale per fermarsi (Knowing-That vs Knowing-How di Ryle).
11. Cohen's Kappa tra metriche automatiche e giudizio manuale di sinonimo è basso (-0.041). La revisione manuale integrale ha recuperato 468 sinonimi validi non captati dalle metriche automatiche.
12. Le tre misure di difficoltà (etichetta dell'autore, cluster su accuratezza, cluster sul tempo) si accordano solo debolmente (Kappa pesato 0.122-0.325). Difficoltà percepita dal modello e difficoltà dichiarata a priori sono costrutti correlati ma non equivalenti.
13. RQ6 (giudizio qualitativo dell'autore): *Claude Opus 5* è il modello scelto, con bias dichiarato dall'autore, per la qualità del processo di ragionamento anziché per l'esattezza pura.
14. Limiti principali: N=1 sul giudizio di riferimento, parametri di sampling non uniformi per i modelli commerciali, riproducibilità non garantita nel tempo (nuovi rilasci/quantizzazioni/backend).
15. Sviluppi futuri: mechanistic interpretability/XAI, ampliare lo spettro di temperature, sottoporre il dataset a revisione umana con N>30.

Abstract

“La ghigliottina” è un gioco televisivo italiano di associazione semantica: cinque parole indizio devono condurre a un’unica parola soluzione attraverso modi di dire, polisemia e collocazioni lessicali. Questo studio traspone il gioco in inglese e lo sottopone a 127 modelli linguistici di grandi dimensioni (LLM), 111 open-weight e 16 commerciali, per indagare se e come i modelli applichino questo tipo di ragionamento associativo. È stato costruito un dataset originale di 30 item in inglese, sottoposto a ciascun modello open-weight a tre temperature (0.0/0.3/0.7) e ai modelli commerciali con un singolo run, per un totale di 9.380 osservazioni valide sui modelli open-weight e 444 sui commerciali.

I risultati rispondono a sei domande di ricerca. Nessun modello coincide sistematicamente con la soluzione di riferimento: il migliore open-weight (*stepfun/step-3.5-flash*, 71.1% di risposte esatte) e il migliore commerciale (*x-ai/grok-4.6*, 76.7%) restano lontani dalla perfezione, e il confronto a coppie (McNemar con correzione FDR) non individua un vincitore statisticamente distinguibile all’interno dei rispettivi gruppi di vertice. Includendo i sinonimi validati manualmente, la correttezza estesa sale fino all’80.0%, segnalando come parte della distanza misurata sia un limite delle metriche automatiche anziché un fallimento semantico dei modelli. In almeno tre item la risposta convergente dei modelli (checkout, stress, watch) risulta più coerente della soluzione originariamente scelta dall’autore. La temperatura non ha un effetto aggregato significativo sull’accuratezza né sul ranking dei modelli, mentre la dimensione del modello correla fortemente con l’accuratezza (Spearman rho fino a 0.756) senza spiegarla del tutto, come dimostra il caso di *gpt-oss:20b*, competitivo nonostante soli 3,61 miliardi di parametri attivi per token grazie all’architettura Mixture-of-Experts. La domanda sul modello migliore secondo il giudizio dell’autore (RQ6) non ammette una risposta puramente statistica: viene proposto *Claude Opus 5*, motivato dalla qualità procedurale del ragionamento osservato anziché l’esattezza aggregata, con bias personale dichiarato esplicitamente.

Al di là delle metriche aggregate, l’analisi qualitativa dei log di ragionamento rivela pattern di fallimento specifici. L’item più difficile in assoluto (PC, accuratezza 0.000 su 193 tentativi) mostra come i modelli notino l’indizio corretto (l’acronimo) e lo scartino, comunque, a favore di forme più naturali come COMPUTER. Il modello *starcoder2:15b-instruct*, in oltre metà delle risposte, risponde correttamente e poi continua a generare codice Python del tutto estraneo al compito fino al limite di token. *deepseek-r1:14b* oscilla ripetutamente tra la risposta corretta (MOUSE) e un’alternativa errata (BEAST) fino a chiudere arbitrariamente sulla risposta sbagliata, pur avendo dichiarato esplicitamente “*I give up; the answer is MOUSE*” poco prima. Questi episodi sono letti attraverso la distinzione di Ryle tra Knowing-That e Knowing-How. I modelli possiedono la conoscenza proposizionale corretta ma mancano del controllo procedurale per arrestarsi su di essa. La rarità lessicale (analisi Zipf) non spiega la difficoltà del dataset nel suo complesso (rho = 0.246, non significativo), ma resta un fattore plausibile per il caso isolato di petrichor, l’unica parola-soluzione genuinamente rara del corpus. Le tre misure di difficoltà impiegate (etichetta dichiarata dall’autore, cluster su accuratezza, cluster sul tempo di generazione) si accordano solo debolmente tra loro (Kappa pesato 0.122-0.325), indicando come la difficoltà percepita dai modelli e quella attribuita a priori dall’autore siano costrutti correlati ma non equivalenti.

Lo studio presenta limiti dichiarati: il giudizio di riferimento (soluzione, difficoltà, coerenza) è a cura di un singolo autore (N=1). I parametri di sampling non sono uniformi tra i modelli commerciali per vincoli strutturali delle interfacce. La riproducibilità dell’esperimento non è garantita nel tempo per i continui rilasci, aggiornamenti e cambi di quantizzazione dei modelli. Sviluppi futuri includono l’uso di tecniche di mechanistic interpretability, l’ampliamento dello spettro di temperature, e la sottoposizione del dataset a revisione umana su un campione più ampio (N>30) per un confronto statisticamente comparabile con le prestazioni dei modelli.

Sommario

Modismi, polisemia e collocazioni lessicali in vari modelli AI.....	0
TL; DR.....	1
Abstract.....	2
Introduzione.....	5
Metodo.....	7
Dataset.....	8
Valutazione preliminare.....	10
Prompt.....	12
Valutazione umana.....	12
Analisi.....	13
Metriche di correttezza.....	13
Scelte statistiche.....	13
Token di ragionamento.....	14
Risultati e commenti.....	15
Statistica descrittiva della distribuzione di accuratezza (modelli con parametri verificati, n=45)	15
Test di normalità.....	15
RQ1 / RQ2 — La soluzione dell'autore coincide con quella dei modelli? Quanto distano quantitativamente?.....	17
Modelli open-weight(108, con IC 95% di Wilson).....	17
Modelli commerciali (16, IC 95% di Wilson, N=30 per modello).....	20
Correttezza estesa (exact + same_root + sinonimo manuale).....	21
Importanza della revisione manuale.....	22
Confronto a coppie tra i modelli migliori (McNemar + FDR).....	22
RQ3 — La risposta di un modello può risultare più coerente di quella dell'autore?.....	23
RQ4 — Quanto la risposta di un modello cambia lungo lo spettro di temperatura?.....	25
Test per singolo modello lungo lo spettro di temperatura.....	25
RQ5 — La dimensione del modello correla con l'accuratezza dell'associazione?.....	29
RQ6 — Quale modello fornisce la risposta migliore, secondo il giudizio dell'autore?.....	32
Calibrazione, discriminazione, classificazione empirica degli item.....	32
Tempo di generazione e token di ragionamento.....	39
Risposta pedissequa dei modelli.....	40
Distribuzione delle risposte.....	41
Analisi Zipf.....	44

Aneddoti e curiosità dai ragionamenti dei modelli	47
Fonti e metodo	47
Guillo_10 (PC) nessuno ha fatto il salto di astrazione.....	47
Guillo_09 (petrichor) — la parola più rara del dataset	48
Guillo_07 (star) — quando il modello ragiona esattamente come l'autore	48
Guillo_28 (mouse) — l'oscillazione MOUSE/BEAST	49
Un intermezzo comico: quando il modello smette di rispondere e inizia a programmare.....	49
Altri item degni di nota	50
Conclusioni	55
Limiti e future ricerche	57
Bibliografia	58
Appendice I.....	59
Appendice II.....	62

Introduzione

“La ghigliottina” è un gioco facente parte di un programma televisivo mandato in onda sull’emittente nazionale italiana denominato “l’eredità” (nomi, termini e condizioni sono di proprietà della RAI radiotelevisione italiana). Il conduttore fornisce cinque coppie di termini. Ad ogni turno il concorrente deve sceglierne una. Scegliendo la parola corretta viene selezionata come indizio, viceversa dimezza il montepremi. Dalla seconda coppia di parole il concorrente può fare delle scelte od operare dei ragionamenti. L’obiettivo finale è avere cinque parole indizio utili per trovare una parola comune (la risposta è preventivamente scelta e depositata da un notaio garantendone l’autenticità e l’unicità) di soluzione. Il concorrente viene sempre a sapere gli indizi corretti. Dopo il dovuto tempo di riflessione, il concorrente svela la parola. Spiega al conduttore e al pubblico quali associazioni ha fatto per arrivare alla parola finale. Se dovessimo riassumere in una domanda lo scopo del gioco sarebbe: quale parola connette i cinque indizi considerati i modi di dire, concetti o connessioni? Se la parola del concorrente è uguale a quella depositata, la somma del montepremi viene erogata, viceversa può tornare nella puntata successiva per avere una seconda possibilità.

Nella puntata del 11 marzo 2025 fornendo le seguenti parole: carta, legno, sogno, effetto, scarpe. La risposta della concorrente è stata: scarpe. La risposta corretta è: lucido. L’associazione corretta: carta da lucido, lucido per legno, sogno lucido, effetto lucido e lucido per scarpe. Nella traduzione inglese l’associazione potrebbe non balzare subito all’attenzione per differenze linguistiche e associazioni semantiche.

Dalle ricerche effettuate, questo gioco non esiste in nessuna altra parte del mondo. Esiste un test psicologico denominato Remote Associate Test (RAT - Olteteanu AM & Hassan Zunjani 2020), un test usato per determinare il potenziale creativo. A differenza del gioco, il RAT ha solo tre parole a cui trovare la quarta. Un esempio l’associazione di queste tre parole: bass, complex, sleep con soluzione deep. Ad un parlante anglofono l’associazione salterebbe subito all’occhio, per un nativo italiano questa associazione è abbastanza oscura. Così come la traduzione inglese del gioco italiano resterebbe oscura ad un anglofono. Il RAT consiste in 30 items da completare in 40 minuti.

Per replicare il gioco in forma inglese non è sufficiente fare la traduzione di quello italiano, ma è necessario creare 30 nuovi item partendo dalla semantica e linguistica inglese in modo da non incorrere nelle problematiche di traduzione con conseguente perdita del senso della risposta. Ad esempio, traducendo in forma letterale le cinque parole precedenti avremo questi cinque indizi: paper, wood, dream, effect, shoes. La parola “Lucido” possiamo tradurla in: shiny. Un anglofono potrebbe fare delle associazioni diverse, ad esempio: Paper - House of paper (o Paper house / casa di carta); Wood - Wooden house / House made of wood (casa in legno); Dream - Dream house (la casa dei sogni); Effect - House effect (come nell’effetto serra: Greenhouse effect, oppure l’impatto visivo/scenico in architettura e teatro), Shoes - House shoes (le pantofole / calzature da casa) e ottenere come parola finale HOUSE. I giochi di associazione semantica basati su modismi, polisemia e collocazioni lessicali, la lingua in cui vengono forniti gli stimoli è fondamentale per ottenere una risposta coerente.

I modelli LLM di ogni dimensione sono stati addestrati utilizzando un vocabolario abbastanza ampio. Per i modelli AI non possiamo parlare di parole, ma di token. Ad esempio, *Llama 3.2 1B* e *3B* hanno 128K token di vocabolario, *Qwen 2.5 1.5B* 151K token mentre *Gemma 2 2B* 256K token. Anche modelli di grandi dimensioni come *GPT4* o la famiglia *Gemini* posseggono rispettivamente 200K e 256K token. Parole complesse, lunghe o in lingua differente da quelle del pre-training possono essere divise in parole più piccole e a volte perdere il significato. I modelli possono essere pre-addestrati monolingue oppure multilingue per avere la capacità di interagire in più nazioni. L’inglese è la lingua con cui tutti i modelli, in percentuale variabile, sono pre-addestrati.

Cosa succederebbe se sottoponessimo a modelli AI di varie dimensioni una versione inglese del gioco della ghigliottina?

In questo scritto andremo ad analizzare e cercare di rispondere alle seguenti domande:

1. La soluzione dell'autore coincide con quella trovata dai modelli?
2. Quanto distano, quantitativamente, le risposte dei modelli dalla soluzione di riferimento?
3. Nell'associazione delle parole, la risposta di un modello può risultare più coerente di quella dell'autore (valutazione linguistica soggettiva)?
4. Quanto la risposta di un modello cambia lungo lo spettro di temperatura, a parità di top_k/top_p?
5. La dimensione del modello (parametri) correla con l'accuratezza dell'associazione?
6. Quale modello fornisce la risposta migliore, secondo il giudizio dell'autore?

L'analisi è durata circa 20 giorni con termine il 22 agosto 2026. I continui rilasci di nuovi modelli, aggiornamenti di quelli esistenti, diverse quantizzazioni o backend di inferenza non garantiscono la riproducibilità totale dell'esperimento.

Metodo

Sono stati selezionati vari modelli LLM di diverse dimensioni e capacità di pensiero per rendere ampio il numero di osservazioni. In totale sono stati utilizzati 127 modelli LLM da 350M parametri e trilioni di parametri. Molti modelli non dichiarano i parametri totali rendendo impossibile identificare un numero preciso. Sono state utilizzate due tipologie di servizi di computing: modelli scaricabili da Ollama (<https://ollama.com/>); servizio di elaborazione on-line (<https://openrouter.ai/>) con l'acquisto di crediti.

L'elaborazione è stata automatizzata creando script personalizzati in Python. I modelli open-weight sono stati elaborati usando il provider Ollama, per i modelli on-line utilizzando le API dedicate del servizio sottoscritto. I dati provvisori sono stati salvati in un file Excel. I dati aggiuntivi forniti dal servizio on-line sono stati salvati in un file JSONL per la successiva analisi. Indipendentemente dal provider su cui hanno elaborato le informazioni, verranno chiamati open-weight.

Il tempo concesso al concorrente per fornire la risposta varia da 30 a 60 secondi (in base alla versione del gioco), ai modelli reasoning open-weight, è stato dato un limite di 600 secondi per il termine del ragionamento. La scelta del tempo è stata identificata da alcune prove preliminari ed empiriche. Mediamente per completare un ragionamento entro il limite dei token a disposizione il tempo variava tra i 420 e i 540 secondi (7 - 9 minuti). Alcuni modelli hanno utilizzato un tempo di oltre 1800 secondi per completare il ragionamento senza fornire una risposta valida (stringa vuota). La decisione dei 600 secondi è data dalle tempistiche di ragionamento e un limite accettabile affinché i modelli potessero generare una risposta valida. Nell'esperimento abbiamo decuplicato i tempi per avere la certezza di ottenere una risposta. Da questa affermazione possiamo porci un'altra domanda: se fornissimo dieci minuti al concorrente per identificare la parola corretta, sarebbe in grado di fornire quella giusta?

Per i restanti modelli questa opzione non era un parametro impostabile.

I dati estrapolati sono stati salvati in un file Excel e successivamente elaborati con un notebook Jupiter.

Dataset

È stato creato un dataset di 30 items contenente cinque parole indizio e una risposta totalmente in inglese. Il significato della risposta è stato esplicitato nel file originale. La creazione delle parole è stata fatta direttamente dall'autore senza aiuti esterni. Per poter valutare sommariamente gli item creati, è stata effettuata una prima revisione con il supporto di un modello AI LLM (*Claude Sonnet 5*). Da questa prima revisione l'autore ha modificato 5 item per rientrare nella categoria ottimale. Ad esempio, uno degli items sostituiti:

Parole: capital; arteriocardiality; recapitulation; escapism; decapitated

Parola accomunante: capi

Difficoltà: hard

Spiegazione: all words have "capi" inside

Le cinque parole non hanno un'associazione di un elemento comune tra loro, non è un'associazione semantica o modi di dire, ma solo uno schema grammaticale. Questo tipo di item non mette a prova il ragionamento associativo, ma la ricerca di differenze/somiglianze grammaticali.

La revisione effettuata dal modello AI LMM non è una validazione. Solo sottoponendo i 30 items a revisione formale possiamo avere una revisione e confermare la correttezza della parola accomunante (come nel RAT).

I 30 items sono stati sottoposti a tutti i modelli secondo le seguenti decisioni metodologiche

Decisione	Scelta	Motivazione
Prompt	Unico, fisso, in inglese, uguale per tutti i modelli	Isola il modello come variabile indipendente. Personalizzare il prompt per modello introdurrebbe un livello di confusione (misurerebbe la qualità del prompt engineering, non la capacità del modello)
Temperature	0.0 / 0.3 / 0.7	Copre lo spettro da deterministico a moderatamente stocastico. A T=0.0 top_k/top_p sono inerti (decoding greedy)
top_k / top_p	40 / 0.9, fissi su tutti i run open-weight	Continuità con i parametri di progetti precedenti
Metriche automatiche	exact_match, same_root (Porter stemmer, nltk), levenshtein_normalized (rapidfuzz, soglia di similarità 0.5)	Confronto case-insensitive. Same_root cattura variazioni morfologiche regolari (non forme irregolari, ma mitigato dalla verifica manuale). Automatizzare una parte semantica facilmente identificare con schemi linguistici
Metriche manuali	synonym_manual, coherence_manual	Compile dall'autore dopo l'acquisizione, non automatizzabili in modo affidabile
Modelli commerciali	Run singolo per modello (non tre temperature), parametri di sampling non controllati	Le interfaccia web non espongono temperature/top_k/top_p; anche via API, provider diversi espongono parametri diversi (es. l'API OpenAI non ha top_k). Trattati come traccia separata, non comparabile 1:1 con gli open-weight

Output	Un file Excel con 4 fogli (T_0.0 / T_0.3 / T_0.7 / Commercial), formato long/tidy. File JSONL per informazioni aggiuntive	Una riga = una generazione con i vari parametri. Salvataggio di parametri utili per un'analisi approfondita.
--------	---	--

Table 1 Decisioni metodologiche applicate

Valutazione preliminare

Ogni item è stato classificato in base ad un arbitrario livello di difficoltà dell'autore. Il livello di difficoltà nel trovare la parola comune da parte di persone potrebbe essere differente. In totale viene proposto un corpus dei 30 item. Al momento della stesura dello scritto non è stata fatta nessuna revisione da parte di soggetti umani. Anche se non fa parte delle domande di ricerca, sarebbe interessante scoprire la differenza di risposte tra AI e umani. A tal proposito il lettore è invitato a partecipare al gioco. Nella tabella sottostante vengono proposti i cinque indizi forniti ai modelli AI. Il lettore è invitato a compilare le due colonne: "Solution" e "Difficulty". Nella colonna "solution" viene inserita la parola ritenuta accomunante e corretta con i cinque indizi (una e una sola parola). Nel campo "difficulty" viene compilata la difficoltà percepita nel riuscire a identificare la parola corretta. I livelli di difficoltà sono 3: 1= easy; 2= medium; 3 = hard. I livelli di difficoltà sono i medesimi utilizzati dall'autore per identificare il parametro di partenza.

Il tempo a disposizione per la compilazione dovrebbe essere di 30 minuti. Al lettore possiamo fornire il tempo desiderato, si richiede di registrare il tempo totale o il tempo per ogni item per poter fare una comparazione con i vari modelli LLM. In appendice I la soluzione, il livello di difficoltà e il motivo per cui è stata attribuita la parola della soluzione.

word1	word2	word3	word4	word5	solution	Difficulty
gluteus	adjustable	sit	office	kitchen		
highway	wheel	transport	fuel	insurance		
Washington	skyscraper	sewer	courthouse	shop		
Pascal	inch	stress	cloud	blood		
moon	speed	lamp	hope	visible		
videogame	human	society	advance	history		
Patrick	sun	wars	five	multiplication		
card	dental	suspension	nose	burn		
rain	arid	perfume	terrain	lift		
CPU	RAM	GPU	HD	VRAM		
language	snake	colt	monty	biceps		
qualification	book	academic	noble	job		
gestational	politics	court	another	substitute		
geometric	meditation	art	powder	sanskrit		
mean	math	analysis	descriptive	inferential		
aircraft	geometry	woodworking	thought	surface		
cloth	rectangular	pole	symbol	signal		
game	television	bird	observe	vigilante		
double	red	fingers	angry	necklace		
exotic	adventure	fly	culture	relax		
exit	shelves	cart	pay	customer		
reaction	response	driven	cognitive	adrenaline		
philosophy	math	physics	business	society		
construct	lamp	problem	innovation	good		
tree	pie	computer	day	York		
love	Plato	essentialism	taoism	knowledge		
renewable	resource	environmental	social	economic		
countryside	hole	whiskers	Mickey	lab		
barrel	web	wood	rusty	cat		
Today	simple	gift	time	now		

Table 2 I 30 item del protocollo di valutazione da sottoporre a soggetti umani per la valutazione revisione

Il lettore è invitato a condividere le sue soluzioni per avere un maggiore margine di valutazione della difficoltà e delle soluzioni trovate. Con un numero sufficiente di risposte da parte dei lettori è possibile comparare le risposte con i modelli LLM.

Prompt

Il prompt è stato generato in base alle linee guida di Ronanki et al. (2025) è usato per tutti i modelli open-weight per non modificare la variabile del prompt.

“You are playing a word-association game. You will be given 5 clue words. Find the single word that connects all five (through common phrases, idioms, or shared concepts). Respond with ONLY the final word, in uppercase, with no explanation. Clues: {word1}, {word2}, {word3}, {word4}, {word5}.”

Nel file Python è stata creata una funzione per isolare la risposta dal reasoning.

Valutazione umana

Al termine dell’elaborazione, il file Excel è stato revisionato dall’autore (revisori N=1). La revisione prevedeva l’inserimento del valore 1 nelle colonne `synonym_manual` e `coherence_manual`. `Synonym_manual` viene compilata se la parola fornita è un sinonimo della parola obiettivo, ad esempio, “travel” può avere sinonimi come “journey” o “voyage”. `coherence_manual` viene compilata se la parola fornita ha una connessione ragionevolmente corretta se comparata con quella obiettivo. Queste colonne non potevano essere compilate in automatico. La revisione umana si è resa necessaria per validare gli output dei vari modelli. Una delle domande di ricerca (RQ3) prevede di comprendere se i modelli forniscono una parola più coerente rispetto a quella impostata, analizzare le risposte e validarle come alternative verificate era necessaria.

Analisi

Al termine della revisione da parte dell'autore sono stati creati degli script Python e notebook per l'analisi dei dati.

In totale sono stati utilizzati 111 modelli open-weight e attesi 90 record ciascuno ($30 \text{ item} \times 3 \text{ temperature}$). Un solo modello risulta incompleto (*arcee-ai/virtuoso-large*, 8/90 righe). Sul totale, 270 righe duplicate (stesso modello/item/temperatura, presenti in più file di origine) sono state rimosse tenendo la prima occorrenza. Dopo il filtro sulla colonna status (status = "ok" esclude timeout ed errori), restano 9.380 osservazioni valide sui modelli open-weight e 444 osservazioni valide sui 16 modelli commerciali (su 480 totali; 36 errori, quasi tutti concentrati su *meta/muse-spark-1.2*, fallendo tutte e 30 le chiamate, e su *inception/mercury-2*, 6 errori su 30). 108 modelli open-weight hanno dati sufficienti per la classifica di accuratezza. I 16 modelli commerciali sono stati raccolti senza parametri di temperatura ottenendo 30 osservazioni.

Metriche di correttezza

Tre metriche automatiche per riga: `exact_match` (uguaglianza esatta con la soluzione attesa), `same_root` (stessa radice morfologica), `is_similar_lev` (similarità di Levenshtein normalizzata sopra soglia). A queste si aggiungono due colonne compilate a mano con revisione completata al 100% su entrambi i dataset: `synonym_manual` (la risposta è un sinonimo valido non catturato dalle metriche automatiche) e `coherence_manual` (giudizio di coerenza linguistica). La colonna `is_clue_echo` (il modello ripete una delle 5 parole indizio invece di trovare il connettore) e `format_compliant` non sono misure di correttezza ma aiutano a interpretarla. Un modello con `exact_match` basso e `is_clue_echo` alto sta fallendo in modo diverso da uno con `is_clue_echo` basso.

Scelte statistiche

- **Intervalli di confidenza di Wilson** (non Wald/normale) per ogni tasso di accuratezza, perché più affidabili con proporzioni vicine a 0 o 1 e campioni non enormi.
- **Correlazione di Spearman** (non Pearson) per RQ5 (dimensione vs accuratezza): interessa se dimensione maggiore e ranking di accuratezza si muovono insieme, non l'esistenza di una relazione lineare.
- **Cochran's Q** (non un chi-quadro) per RQ4: gli stessi 30 item vengono ripresentati allo stesso modello a tre temperature, disegno a misure ripetute non campioni indipendenti.
- **McNemar + correzione FDR (Benjamini-Hochberg)** per il confronto a coppie tra i modelli migliori. I dati sono appaiati e con più confronti in parallelo il rischio di falsi positivi cresce. La correzione FDR è necessaria, non opzionale.
- **Cohen's Kappa** per quantificare quanto le metriche automatiche (`same_root`, `is_similar_lev`) catturano da sole quanto la revisione manuale (`synonym_manual`) ha giudicato un sinonimo valido tra le risposte non esatte.
- **Kappa pesato (scala Landis & Koch 1977)**, non il kappa grezzo, per confrontare le tre etichette di difficoltà (dichiarata dall'autore, cluster su accuratezza, cluster su tempo di generazione). Sono categorie ordinate, sbagliare hard/easy è un disaccordo peggiore di hard/medium.
- **Correlazione punto-biseriale** (Classical Test Theory, presa in prestito dalla psicometria) per l'indice di discriminazione degli item. Per ogni item, correlazione tra "il modello lo risolve" e il punteggio totale del modello sugli altri 29 item.

- **Clustering k-means 1D** sull'accuratezza per item, con silhouette score per stabilire quanti gruppi sono davvero supportati dai dati, invece di assumere a priori 3 o 5
- **Bootstrap per-modello (2.000 resample)** per l'intervallo di confidenza della correlazione dimensione/accuratezza (RQ5).
- **Leave-one-out cross-validation** per scegliere il grado del fit tempo/accuratezza (RQ4/tempo come proxy di difficoltà). Con $N=30$ item, un polinomio di grado alto migliora sempre l' R^2 dentro-campione senza generalizzare meglio. La LOOCV misura la vera capacità predittiva.
- **Shapiro-Wilk** (più adatto di Kolmogorov-Smirnov per N piccoli) più Q-Q plot per il test di normalità della distribuzione di accuratezza tra modelli.

Token di ragionamento

Un notebook separato analizza i log grezzi JSONL delle chiamate OpenRouter i quali contengono il conteggio nativo di token di ragionamento fornito da ciascun provider. Questo permette di verificare empiricamente (non per inferenza dal nome del modello) quali modelli ragionano davvero, e di collegare la durata di generazione al numero di token effettivamente calcolati. Inoltre, avendo il reasoning, possiamo leggere come il modello è arrivato alla risposta.

Risultati e commenti

Fornire risultati e commenti contemporaneamente prevede un differente stile linguistico e comunicativo. Esporre dati in forma asettica e commentarli in forma discorsiva permette di analizzare il contenuto numerico e commentarlo senza il formalismo accademico. Nella parte precedente vi è stato un formalismo maggiore per l'esposizione delle informazioni, in queste sezioni il formalismo riduce a favore di una maggiore comprensione.

Statistica descrittiva della distribuzione di accuratezza (modelli con parametri verificati, n=45)

Statistica descrittiva di base sulla distribuzione di `exact_match` tra i 45 modelli con conteggio di parametri verificato. Gli altri modelli sono stati esclusi non avendo il numero di parametri dichiarati.

Statistica	Valore
n modelli	45
Media	0.2758
Mediana	0.2889
Deviazione standard	0.1797
Varianza	0.0323
Asimmetria (skewness)	0.0707
Curtosi (eccesso)	-1.0176
Minimo	0.0000
Massimo	0.6207
IQR (Q3-Q1)	0.2832

Table 3 Statistica descrittiva dei modelli (N=45) con parametri dichiarati e/o noti

L'asimmetria vicina a zero (0.07) definisce la distribuzione senza coda marcata da un lato o dall'altro. Media e mediana sono quasi coincidenti (0.276 vs 0.289). La curtosi negativa (-1.02) indica una distribuzione più piatta di una normale con meno concentrazione al centro e più modelli distribuiti verso gli estremi rispetto a quanto una normale prevederebbe. Visivamente coerente con una lista sia con modelli quasi-zero (*Hudson/gpt2*, *tinyllama*) sia con modelli sotto il 60% (*gpt-oss:20b* al 57.8%, *qwen3.8:27b* al 54.4%), senza un forte addensamento a metà classifica.

Test di normalità

Shapiro-Wilk sulla distribuzione con valori $W = 0.9587$, $p = 0.1094$, compatibile con la normalità ($p > 0.05$). Anche se la curtosi negativa vista sopra suggerisce di non fidarsi ciecamente di un singolo test di significatività su un campione di questa dimensione. L'affiancamento con un Q-Q plot per un controllo visivo fornisce dove eventuali scostamenti si concentrino (code o centro).




Figure 1 Distribuzione tra modelli con parametri dichiarati ($N=45$) a sinistra. *QQ plot per normalità* a destra

Il valore dell'analisi preliminare conferma come la forma non sia patologicamente distorta (bimodale, con outlier estremi), questo renderebbe fuorviante parlare di una distribuzione di accuratezza tra modelli. La maggior parte delle analisi usa metodi non parametrici per scelta metodologica indipendente (Spearman al posto di Pearson, McNemar/Cochran's Q al posto di test basati su normalità). L'analisi preliminare conferma solamente la scelta dell'analisi e dei metodi utilizzati successivamente.

RQ1 / RQ2 — La soluzione dell'autore coincide con quella dei modelli? Quanto distano quantitativamente?

Modelli open-weight(108, con IC 95% di Wilson)

Il modello con `exact_match` nominale più alto, `z-ai/glm-5.2:free` (75.0%) va scartato come “leader” in quanto possiede solo 4 osservazioni valide su 90 attese (86 errori) e il suo IC 95% ha una notevole ampiezza (0.301- 0.954). Nella tabella la classifica dei 10 modelli con più risposte esatte (`exact_match`).

Model	n	exact_match	same_root	is_clue_echo	CI 95%
<i>stepfun/step-3.5-flash</i>	90	0.711	0.778	0.0	[0.610 , 0.795]
<i>bytedance-seed/seed-2-1-turbo</i>	90	0.678	0.744	0.0	[0.576 , 0.765]
<i>nvidia/nemotron-3-ultra-550b-a55b</i>	90	0.678	0.744	0.0	[0.576 , 0.765]
<i>moonshotai/kimi-k2.5</i>	89	0.663	0.73	0.0	[0.56 , 0.753]
<i>xiaomi/mimo-v2.5-pro</i>	90	0.656	0.722	0.0	[0.553 , 0.746]
<i>qwen/qwen3.7-plus</i>	89	0.629	0.697	0.0	[0.525 , 0.722]
<i>olmo-3.1:32b</i>	58	0.621	0.69	0.0	[0.492 , 0.734]
<i>z-ai/glm-4.7</i>	88	0.614	0.659	0.0	[0.509 , 0.709]
<i>deepseek/deepseek-r1-0528</i>	90	0.611	0.678	0.0	[0.508 , 0.705]
<i>tencent/hy3</i>	90	0.6	0.667	0.0	[0.497 , 0.695]

Table 4 Top 10 modelli open-weight ordinati per risposte esatte (`exact_match`)

In fondo alla classifica, cinque modelli a `exact_match` = 0.000: *tinylama:1.1b*, *starcoder2:15b*, *granite4:350m*, *Hudson/gpt2-instruct:345m-q8_0*, *meta-llama/llama-3.2-1b-instruct*.

Tre di questi cinque hanno un tasso di `is_clue_echo` molto alto a conferma della mancata risoluzione del compito, ma ripetono una delle clue date invece di trovare il connettore. *Starcoder2:15b* pur fallendo ha `is_clue_echo` basso (0.022) ma `format_compliant` = 0.000, coerente con l'iniezione di testo/codice estraneo. *Meta-llama/llama-3.2-1b-instruct* ha `format_compliant` = 0.978 (rispetta il formato richiesto) ma `is_clue_echo` solo 0.189, questo determina come il suo fallimento non è né eco né violazione di formato, semplicemente non trova la parola giusta.

Model	n	exact_match	same_root	is_clue_echo	CI 95%
<i>tinylama:1.1b</i>	90	0.0	0.0	0.767	[0.0 , 0.041]
<i>starcoder2:15b</i>	89	0.0	0.0	0.022	[0.0 , 0.041]
<i>granite4:350m</i>	90	0.0	0.0	0.611	[0.0 , 0.041]
<i>Hudson/gpt2-instruct:345m-q8_0</i>	90	0.0	0.022	0.7	[0.0 , 0.041]
<i>meta-llama/llama-3.2-1b-instruct</i>	90	0.0	0.0	0.189	[0.0 , 0.041]
<i>stablelm2:1.6b-chat</i>	90	0.022	0.022	0.744	[0.006 , 0.077]
<i>deepseek-r1:1.5b</i>	85	0.024	0.047	0.447	[0.006 , 0.082]
<i>orca-mini:3b</i>	90	0.033	0.044	0.778	[0.0110 , 0.093]
<i>minicpm-v4.6:1b</i>	90	0.067	0.1	0.489	[0.0310 , 0.138]
<i>ministral-3:3b</i>	90	0.111	0.156	0.0	[0.0610 , 0.193]

Table 5 Bottom 10 modelli open-weight ordinati per risposte esatte (`exact_match`)




Figure 2 Exact_match per modelli open-weight con dati aggregati per temperatura




Figure 3 Classifica con livelli di incertezza e indice di confidenza (CI95%). Linea tratteggiata gialla = mediana. Linea continua bianca = media. La zona ombreggiata grigia copre una deviazione standard. Modelli con punto rosso indicano modelli reasoning. Barre orizzontali = indice di confidenza

Modelli commerciali (16, IC 95% di Wilson, N=30 per modello)

Modello	n	exact_match	same_root	is_clue_echo	CI 95%
<i>x-ai/grok-4.6</i>	30	0.767	0.833	0.0	[0.591 , 0.882]
<i>google/gemini-3.7-flash</i>	30	0.733	0.800	0.0	[0.556 , 0.858]
<i>anthropic/claude-opus-5</i>	30	0.700	0.767	0.0	[0.521 , 0.833]
<i>moonshotai/kimi-k3</i>	30	0.700	0.767	0.0	[0.521 , 0.833]
<i>openai/gpt-5.6-sol</i>	30	0.700	0.767	0.0	[0.521 , 0.833]
<i>openai/gpt-5.5</i>	30	0.667	0.733	0.0	[0.488 , 0.808]
<i>anthropic/claude-sonnet-5</i>	30	0.667	0.733	0.0	[0.488 , 0.808]
<i>z-ai/glm-5.3</i>	30	0.667	0.733	0.0	[0.488 , 0.808]
<i>deepseek/deepseek-v4-pro-0813</i>	30	0.633	0.700	0.0	[0.455 , 0.781]
<i>inception/mercury-2</i>	24	0.583	0.667	0.0	[0.388 , 0.755]
<i>anthropic/claude-haiku-4.5</i>	30	0.567	0.633	0.0	[0.392 , 0.726]
<i>qwen/qwen3.8-max</i>	30	0.567	0.633	0.0	[0.392 , 0.726]
<i>cohere/command-a</i>	30	0.533	0.600	0.0	[0.361 , 0.698]
<i>openai/gpt-5.4</i>	30	0.533	0.600	0.0	[0.361 , 0.698]
<i>openai/gpt-5.4-mini</i>	30	0.433	0.500	0.0	[0.274 , 0.608]

Table 6 Classifica di tutti i modelli commerciali ordinati per exact_match

meta/muse-spark-1.2 ha fallito tutte le 30 chiamate (escluso dalla classifica).




Figure 4 Classifica con livelli di incertezza e indice di confidenza (CI95%). Linea continua rossa = media. Barre orizzontali = indice di confidenza

Correttezza estesa (exact + same_root + sinonimo manuale)

Includendo anche i sinonimi validati a mano, il quadro cambia leggermente: *bytedance-seed/seed-2-1-turbo* sale al primo posto (80.0% di correttezza estesa, *broad_correct*), seguito da *nvidia/nemotron-3-ultra-550b-a55b* (78.9%) e *stepfun/step-3.5-flash* (78.9%).




Figure 5 Composizione delle risposte per modelli open-weight con dati aggregati. Verde scuro = *exact_match*. Verde chiaro = radice comune. Rosa = sinonimo. Grigio = sbagliato.

Versione per i soli modelli commerciali




Figure 6 Composizione delle risposte per modelli commerciali con dati aggregati. Verde scuro = `exact_match`. Verde chiaro = `radice comune`. Rosa = `sinonimo`. Grigio = `sbagliato`.

Importanza della revisione manuale

L'accordo tra le metriche automatiche (`same_root` o `is_similar_lev`) e il giudizio manuale di sinonimo, tra le risposte non esatte fornisce un dato Cohen's Kappa = -0.041 (accordo grezzo 81.9%, kappa corregge per l'accordo dovuto al caso). Le metriche automatiche da sole non avrebbero catturato 468 sinonimi validi su 5.732 righe non esatte revisionate. La revisione manuale integrale conferma il reale utilizzo e valore statistico, non un controllo prudenziale ridondante.

Confronto a coppie tra i modelli migliori (McNemar + FDR)

Tra i primi 8 modelli open-weight, 0 coppie su 21 restano significativamente diverse dopo la correzione FDR ($p < 0.05$). Stesso esito tra i primi 8 commerciali con 0 coppie su 28. In entrambi i gruppi con $N \text{ item} = 30$, il migliore modello nominale non è statisticamente distinguibile dagli altri modelli di vertice, un punto rilevante per non sovra-interpretare la posizione esatta in classifica dei modelli di testa.

RQ3 — La risposta di un modello può risultare più coerente di quella dell'autore?

Matematicamente è difficile da dimostrare in modo rigoroso se le risposte dei modelli LLM possono essere più validi o coerenti di quelli umani, questo tipo di risposta è una risposta qualitativa anziché quantitativa.

Entrambe le colonne di valutazione manuale sono compilate al 100% (9.380/9.380 righe open-weight, 444/444 commerciali). I modelli con il tasso più alto di risposte giudicate sinonimo valido (synonym_manual) tra gli open-weight sono *gemma2:9b* (14.4%), *minicpm-v4.5:8b* (13.3%), *gemma3:12b* (13.3%). Per la coerenza linguistica (coherence_manual) il tasso più alto è *gemma3:12b* (23.3%), seguito da *ibm-granite/granite-4.0-h-micro* (21.1%) e *minicpm-v4.5:8b* (21.1%).

Qualitativamente i candidati su cui sottoporre l'attenzione sono:

- Guillo_21 (supermarket con checkout). La risposta più comune non è checkout (30.0%) ma store (43.2%) quest'ultima usa la strategia dell'autore "tutto sta dentro un negozio/supermercato". Solo con una parola più generica, un sinonimo più vago, non un'idea migliore. Checkout invece è concettualmente diverso. Non è un contenitore, ma un processo interpretabile come una fase del processo (exit, si esce dal checkout. Shelves, portano al checkout. Cart, si usa fino al checkout. Pay è il checkout. Customer è chi fa il checkout). Possiamo identificare checkout come il candidato migliore, non per percentuale di risposte fornite, per associazione dei comportamenti o degli strumenti utilizzati. Entrambe possono essere valide allo stesso modo.
- Guillo_22 (Emotion con stress) emotion la dà solo il 3.9% dei tentativi, mentre stress domina al 33.8%. Diversi ragionamenti arrivano a STRESS per esclusione sistematica di alternative (reflex, stimulus, impulse...). Lo schema più convincente è quello fornito da *gpt-oss-120b* e cita: "Reaction: 'stress reaction' yes. Response: 'stress response'. Driven: 'stress-driven'. Cognitive: 'cognitive stress'. Adrenaline: 'adrenaline stress'? Usually..." Quattro collocazioni idiomatiche fortissime (stress reaction, stress response, stress-driven, cognitive stress), solo l'ultima leggermente forzata segnalata anche dal modello. La giustificazione originale nel dataset è oggettivamente più debole e un po' circolare ("emotion reach a reaction and a response, emotion drive our behaviour...", usa "emotion" per spiegare perché la risposta è "emotion"). Stress è un'associazione più stretta comparata a quella dell'autore.
- Guillo_18 (watching con watch). Qui non è un disaccordo di concetto, è un disaccordo di forma con cui viene scritta la parola. Praticamente ogni modello risponde watch, non watching (198/339 con il 58.4% nel solo set open-weight, same_root=1). L'associazione (game watching, TV watching, bird watching, vigilante watching) è quella giusta al 100%. Da una riflessione a posteriori, il gerundio è la forma meno naturale per la parola-connettore, e quasi nessun modello ci arriva. L'item conferma la correttezza dell'associazione, ma la scelta della forma grammaticale della soluzione ha reso l'item quasi impossibile da centrare esattamente.

In questi casi la maggioranza dei modelli produce una spiegazione clue-per-clue più stretta. Dopo revisione manuale, in entrambi i casi la giustificazione originale nel dataset è tra le più deboli o generiche.

Casi scartati:

- Guillo_20 (travel vs vacation, 36% vs 27%): vacation è quasi sinonimo di travel su queste clue (exotic, adventure, fly, culture, relax), non è un'idea diversa o migliore, è la stessa idea con un'altra parola.

- Guillo_24 (idea vs light/solution): light vince solo sulla clue “lamp” (via l’idioma lightbulb moment) ma non regge su construct/problem/innovation/good come idea. Idea resta la risposta più solida.
- Guillo_23 (concept) zero modelli su 487 tentativi hanno mai risposto “concept”, nemmeno i migliori commerciali. Le alternative dominanti (theory 25.9%, science 25.7%) non sono chiaramente migliori: “business theory” è meno naturale di “business concept”, “society theory” è inusuale. È un caso anomalo in quanto non si tratta di trovare una parola più adeguata, la categoria astratta e nessuna singola parola vince davvero, è un problema di design dell’item anziché la capacità dei modelli di estrapolare la parola corretta.
- guillo_29 (scraping): spider (18.9%) coglie solo la clue “web”, non le altre quattro. Questo è un esempio di ancoraggio su un’associazione utilizzando parzialmente gli indizi forniti, non una soluzione alternativa completa.

RQ4 — Quanto la risposta di un modello cambia lungo lo spettro di temperatura?

Valutando le risposte lungo lo spettro di temperatura, otteniamo una accuratezza del 39.3% a $T=0.0$ (1.201/3.057), 38.7% a $T=0.3$ (1.219/3.152), 38.7% a $T=0.7$ (1.228/3.171). Questa differenza non è statisticamente significativa, i dati Cochran's Q aggregato = 0.558, $p = 0.757$ (3.023 coppie modello x item con tutte e 3 le temperature, 434 con esito variabile). Questi dati confermano come la temperatura non sia un parametro discriminante per valutare l'esattezza delle risposte.




Figure 7 Distribuzione dell'accuratezza per item lungo lo spettro della temperatura ($T=0.0/0.3/0.7$)




Figure 8 dati aggregati della percentuale di risposte esatte lungo lo spettro di temperatura.

Test per singolo modello lungo lo spettro di temperatura

12 modelli non sono testabili, nessun item cambia esito tra le temperature in quanto sono senza varianza da testare. Tra i modelli testabili, 9 risultano sensibili alla temperatura con $p < 0.05$, senza correzione per confronti multipli: *gemma4:26b* ($Q=12.20$, $p=0.0022$), *gemma4:12b* ($Q=7.60$, $p=0.0224$), *nousresearch/hermes-4-70b* ($Q=7.00$, $p=0.0302$), *gemma4:e4b* ($Q=6.89$, $p=0.0319$), *deepseek-r1:7b* ($Q=6.33$, $p=0.0421$), *tencent/hunyuan-a13b-instruct* ($Q=6.22$, $p=0.0446$), *starcode2:15b-instruct*, *ministral-3:14b* e *thinkingmachines/inkling-small* ($Q=6.00$, $p=0.0498$ per tutti e tre).

Per ampiezza dello spostamento (max–min accuratezza tra le tre T): *z-ai/glm-5.2:free* e *google/gemma-4-26b-a4b-it:free* (0.333 entrambi), *gemma4:26b* (0.300), *tencent/hunyuan-a13b-instruct* e *gemma4:e4b* (0.200 entrambi).

Il ranking dei modelli per accuratezza resta stabile tra temperature. Le correlazione di Spearman tra ranking $T=0.0/T=0.3 = 0.920$, $T=0.0/T=0.7 = 0.886$, $T=0.3/T=0.7 = 0.930$ (tutti con $p < 0.0001$).

Ci sono modelli più sensibili alla temperatura spostando l'accuratezza assoluta di alcuni punti. Questo è un segnale di misurazione affidabile e di flessibilità di risposta. Il calcolo non è applicabile ai modelli commerciali con elaborazione singola e nessun asse di temperatura.




Figure 9 Heatmap utilizzando exact_match per i modelli open-weight lungo lo spettro di temperatura.




Figure 10 Percentuale di risposte esatte (*exact_match*) ordinate per item. Blu = $T=0.0$, Arancione $T=0.3$, Verde $T=0.7$.

In generale si osserva una eguaglianza di risposte esatte alle tre temperature impostate per ogni item confermando come l'andamento generale delle risposte non sia determinato dalla temperatura.

RQ5 — La dimensione del modello correla con l'accuratezza dell'associazione?

Il numero di parametri rappresenta la capacità potenziale di astrazione e rielaborazione di un modello. A parità di qualità dei dati di addestramento, un numero maggiore di parametri permette al modello di cogliere sfumature più complesse, connettere materie diverse e sviluppare un ragionamento più profondo anziché fermarsi ai concetti base.

Alcuni modelli riportano nel tag la dimensione effettiva in base al numero dei parametri. 41 sono stati esclusi perché il tag non riporta una dimensione. Attraverso una ricerca sistematica, sono stati trovati i parametri dichiarati di altri modelli, ma non tutti quelli utilizzati. In base ai dati disponibili possiamo identificare un totale di 70 modelli con parametri dichiarati. Applicando la relazione tra parametri ed `exact_match` otteniamo un valore di Spearman $\rho = 0.827$ (tutti i modelli), $\rho = 0.842$ (solo non-reasoning). Bootstrap 95% CI (2.000 resample) [0.701, 0.910] la quale indica una correlazione forte e ragionevolmente precisa.

Approfondendo l'analisi con conteggi di parametri verificati su model card/technical dei report ufficiali (45 modelli, non ricavati dal tag) otteniamo un valore di $\rho = 0.756$ (parametri totali del checkpoint) contro $\rho = 0.690$ per parametri attivi per token rilevante nei modelli Mixture-of-Experts o con Per-Layer Embeddings, dove i due numeri divergono molto. Il caso più netto *gpt-oss:20b* ha 20.9B di parametri totali ma solo 3.61B attivi per token (MoE, 32 esperti, top-4 routing), eppure `exact_match` = 0.578. La correlazione dimensione/accuratezza è quindi solida ma non spiega tutto. Poco più della metà dei modelli con parametri dichiarati non è sufficiente per confermare l'esattezza di questo calcolo o rispondere completamente alla domanda. Il calcolo effettivo per token conta, non solo la dimensione dichiarata del checkpoint.




Figure 11 Dimensione vs accuratezza dei modelli con parametri dichiarati o estrapolati. In rosso i modelli con reasoning noto




Figure 12 Parametri totali (checkpoint) vs Parametri attivi per token ($\rho=0.756$ e $\rho=0.690$), in giallo i modelli MoE

RQ6 — Quale modello fornisce la risposta migliore, secondo il giudizio dell'autore?

Questa domanda è per costruzione un giudizio qualitativo non derivabile da numeri aggregati. I dati finali forniscono la base oggettiva su cui appoggiare la scelta. Ulteriori analisi sono necessarie per poter fornire una risposta oggettivamente solida.

Calibrazione, discriminazione, classificazione empirica degli item

Sono stati identificati gli item più difficili e i più facili dell'elaborazione dei modelli open-weight calcolando quante volte hanno fornito una risposta esatta. L'accuratezza media su tutti i 108 modelli ha identificato i seguenti item come quelli più difficili:

- guillo_10 (pc, 0.000)
- guillo_09 (petrichor, 0.000)
- guillo_23 (concept, 0.000)
- guillo_18 (watching, 0.003)
- guillo_29 (scraping, 0.003)
- guillo_21 (supermarket, 0.013)
- guillo_22 (emotion, 0.035)
- guillo_15 (statistic, 0.041)

Mentre gli item più facili:

- guillo_17 (flag, 0.895)
- guillo_05 (light, 0.818)
- guillo_30 (present, 0.775)

Lo stesso schema si ritrova, quasi identico, tra i modelli commerciali. Gli item più difficili sono con valori vicino o praticamente 0.000:

- guillo_15
- guillo_10
- guillo_22
- guillo_18
- guillo_29
- guillo_23

La correlazione di Spearman tra la difficoltà per item vista dai 108 modelli open-weight e quella vista dai 16 commerciali è $\rho = 0.866$ ($p < 0.0001$). La nozione di “item difficile” è la stessa indipendentemente dal livello dei modelli, un risultato di validità convergente rilevante indipendentemente dal tipo di modello, dimensione o capacità di ragionamento.




Figure 13 Accuratezza per item con dati aggregati compresi gli open-wight e i commerciali

La calibrazione delle etichette di difficoltà dichiarate a priori dall'autore (difficulty_note) hanno una accuratezza media dello 0.487 per "easy" (1.250 righe), 0.407 per "medium" (5.010 righe), 0.320 per "hard" (3.120 righe), l'ordinamento è quello atteso, ma con ampia sovrapposizione tra fasce.

Volendo ampliare il numero delle classi oltre le tre fornite, il silhouette score non indica un k ottimale netto: k=2: 0.650, k=3: 0.669, k=4: 0.656, k=5: 0.670, k=6: 0.701. Vi è un aumento di k senza un gomito marcato. A parità di granularità con le 3 etichette (k=3), i confini empirici cadono a exact_match = 0.111 (hard - medium) e 0.499 (medium - easy). 18 item su 30 (60%) risultano in disaccordo con l'etichetta dell'autore e il cluster empirico con una divergenza sostanziale.




Figure 14 Classificazione con $k=3$, k-means, in base alle etichette hard, medium, easy fornite dall'autore

L'autore, attraverso una valutazione visiva del grafico, ha ipotizzato una classificazione a $k=5$. I confini ipotetici: very hard - hard = 0.111; hard - medium = 0.252; medium - easy = 0.499, easy - very easy = 0.700. Questa ulteriore parcellizzazione delle difficoltà al solo scopo di identificare una diversa suddivisione identificando due estremi diversi (very hard e very easy).




Figure 15 Classificazione con $k=5$, k-means, in base alle etichette very hard, hard, medium, easy, very easy ipotizzate dall'autore

Osservando il grafico si potrebbero fare ulteriori suddivisioni, ma come accennato precedentemente non vi sarebbero differenze marcate tra le categorie.

L'indice di discriminazione con correlazione punto-biseriale della Classical Test Theory ha identificato 3 item non testabili per assenza di varianza: guillo_09, guillo_10, guillo_23. Discriminazione più bassa o negativa come candidati alla revisione dell'item, non dei modelli: guillo_15 (-0.161), guillo_18 (-0.146), guillo_22 (-0.094), guillo_03 (0.069), guillo_21 (0.122).

La validità convergente delle tre misure di difficoltà (etichetta dichiarata, cluster su accuratezza, cluster sul tempo di generazione dei soli modelli reasoning) fornisce un kappa pesato molto basso:

- etichetta-vs-accuratezza = 0.122 (slight)
- etichetta-vs-tempo = 0.145 (slight)
- accuratezza-vs-tempo = 0.325 (fair)

Il tempo di generazione si accorda discretamente con l'accuratezza identificando una difficoltà realmente vissuta dal modello, ma quasi per niente con l'etichetta dell'autore, costrutti imparentati ma non sovrapponibili. questo non è un errore da correggere ma un risultato interessante per capire come l'interpretazione umana e dei modelli AI sia diversa.

Item	difficulty_note	cluster_accuracy	cluster_time	exact_match	duration_mean (sec)	is_clue_echo
guillo_01	easy	easy	easy	0.751	47.44	0.064
guillo_02	easy	easy	easy	0.559	60.571	0.07
guillo_03	medium	medium	hard	0.182	229.136	0.064
guillo_04	medium	easy	easy	0.654	57.284	0.105
guillo_05	medium	easy	easy	0.818	23.961	0.041
guillo_06	medium	medium	easy	0.39	53.384	0.048
guillo_07	medium	medium	easy	0.465	84.72	0.116
guillo_08	hard	easy	easy	0.569	56.83	0.08
guillo_09	hard	hard	hard	0.0	295.052	0.084
guillo_10	easy	hard	easy	0.0	62.85	0.058
guillo_11	medium	easy	medium	0.546	162.469	0.065
guillo_12	medium	medium	easy	0.363	99.316	0.077
guillo_13	hard	medium	easy	0.201	70.938	0.111
guillo_14	hard	easy	easy	0.534	36.83	0.083
guillo_15	medium	hard	easy	0.041	9.231	0.06
guillo_16	hard	easy	easy	0.653	25.465	0.079
guillo_17	medium	easy	easy	0.895	7.768	0.057
guillo_18	medium	hard	easy	0.003	64.501	0.058
guillo_19	hard	medium	easy	0.345	70.994	0.074
guillo_20	medium	medium	medium	0.315	156.197	0.048
guillo_21	medium	hard	easy	0.013	82.955	0.08
guillo_22	medium	hard	medium	0.035	146.481	0.177
guillo_23	hard	hard	medium	0.0	186.665	0.029
guillo_24	hard	medium	medium	0.212	191.056	0.061
guillo_25	easy	easy	easy	0.635	77.862	0.096
guillo_26	medium	medium	medium	0.292	127.042	0.092
guillo_27	hard	easy	easy	0.668	57.75	0.022
guillo_28	medium	easy	easy	0.732	28.712	0.07
guillo_29	hard	hard	hard	0.003	260.927	0.156
guillo_30	medium	easy	easy	0.775	27.909	0.102

Table 7 Confronto tra classificazione umana e classificazione tra i modelli in base al tempo di esecuzione del compito. Evidenziati e in grassetto l'item con durata di elaborazione più lungo e il più corto

Di seguito la visualizzazione grafica della tabella precedente.




Figure 16 Durata media per item (barre) in secondi con exact mach medio al centro (ordinate per durata)

Nell'heat map sono racchiusi i dati di Spearman rho.




Figure 17 Matrice di correlazione tra i segnali di difficoltà

Non solo il tempo di generazione influisce sulla difficoltà, ma anche il numero di token di ragionamento e comportamenti dei modelli reasoning. Usando il tempo come parametro di difficoltà (solo modelli reasoning) la correlazione di Spearman tra tempo medio di generazione per item e accuratezza media per item con $\rho = -0.672$ ($p < 0.0001$). Gli item più lenti da generare tendono ad avere accuratezza più bassa. Una regressione lineare di primo grado ha R^2 dentro-campione 0.356 e R^2 leave-one-out 0.281. Gradi superiori della regressione peggiorano la capacità predittiva fuori campione. Con un grado 4 R^2 leave-one-out = -0.061 confermando la peggiore predizione comparata alla semplice media a conferma di come la relazione vada trattata come lineare, non con un polinomio più complesso.




Figure 18 Durata media di generazione ed esattezza (Y1 barre blu) per item *dei* modelli reasoning. Y2 *exact match medio* dei soli modelli reasoning (linea rossa)




Figure 19 Tempo Vs accuratezza per item (punti blu) con regressione lineare (linea rossa) solo per i modelli reasoning

Confrontando i tempi di generazione tra modelli reasoning vs non-reasoning si evidenzia una enorme differenza di variabilità. Un modello reasoning come *z-ai/glm-4.7* ha durata media 397.8s (deviazione standard 820.2s, $n=88$); i modelli non-reasoning hanno tempi quasi costanti ($\sim 2.2\text{--}2.5\text{s}$, deviazione standard $\sim 0.1\text{s}$). Escludendo gli outlier con *exact_match* uguale a zero, R^2 guadagnerebbe qualche punto e la retta calzerebbe meglio con i dati.




Figure 20 Tempo di generazione per modelli open-weight (rosso = reasoning noto)

La classificazione dei modelli reasoning è avvenuta in maniera empirica basata sull'osservazione diretta del tag <think> nella risposta trovando 44 modelli in entrambi i casi. La lista di marker è ben calibrata per questo dato. Dai log grezzi OpenRouter, 5.422 chiamate uniche hanno il campo nativo `reasoning_tokens` conferma direttamente identificando il modello con ragionamento esposto (ad esempio *qwen/qwen3.7-flash* con una media di 24.352,8 token) e quale modello ha il reasoning, ma non lo espone (ad esempio *openai/gpt-3.5-turbo*, *openai/gpt-4o-mini*, *saol0k/l3-lunaris-8b*, *upstage/solar-pro-3/4*). Anche il tempo di ragionamento è un dato fornito dai log grezzi. La correlazione di Spearman è compresa tra 0.71 e 0.999 per la maggior parte dei modelli. L'unica eccezione è *liquid/lfm-2.5-2.6b:free*, $\rho=0.467$ ma non significativo, $p=0.205$ con solo 9 osservazioni disponibili. La velocità di inferenza varia enormemente tra provider passando da ~211 token/secondo (*liquid/lfm-2.5-2.6b:free*) a ~20 token/secondo (*openai/gpt-oss-20b:free*). Il rapporto tra la durata del reasoning e il tempo di ragionamento spiegano in modo quasi sempre molto forte la correlazione.

Tempo di generazione e token di ragionamento

Per l'inglese standard il rapporto caratteri/token nel testo di ragionamento mostrato è vicino a 4 per quasi tutti i modelli. Per *bytedance-seed/seed-2-1-turbo* invece siamo a 0.89 caratteri/token ad indicare come il testo di ragionamento visualizzato è un riassunto molto più corto di quanto il conteggio fatturato implichi, di fatto non mostra il ragionamento integrale. Il tasso secondi/token è una misura comparabile alla velocità pura di inferenza, tra provider diversi possiamo effettuare una normalizzazione della velocità di inferenza in quanto i dati forniti sono i token e il tempo effettivo utilizzato.

Model	n	Rho token_durata	p_value	s_token mediana	Token_sec
<i>qwen/qwen3.7-flash</i>	90	0.9921	0.0000	0.0058	172,4
<i>qwen/qwen3.5-122b-a10b</i>	88	0.9216	0.0000	0.0100	100,0
<i>z-ai/glm-4.7-flash</i>	90	0.9490	0.0000	0.0146	68,5
<i>arcee-ai/trinity-large-thinking</i>	89	0.9792	0.0000	0.0058	172,4
<i>moonshotai/kimi-k2.5</i>	88	0.9746	0.0000	0.0176	56,8
<i>z-ai/glm-4.7</i>	88	0.8254	0.0000	0.0193	51,8
<i>qwen/qwen3.7-plus</i>	89	0.9988	0.0000	0.0179	55,9
<i>deepseek/deepseek-v4-flash-0731</i>	82	0.8328	0.0000	0.0221	45,2
<i>thinkingmachines/inkling-small</i>	90	0.7612	0.0000	0.0104	96,2
<i>tencent/hy3</i>	90	0.9754	0.0000	0.0172	58,1
<i>qwen/qwen3-next-80b-a3b-thinking</i>	90	0.9497	0.0000	0.0071	140,8
<i>bytedance-seed/seed-2-1-turbo</i>	90	0.9973	0.0000	0.0171	58,5
<i>inclusionai/ling-3.0-flash</i>	90	0.8886	0.0000	0.0053	188,7
<i>nex-agi/nex-n2-mini</i>	90	0.9602	0.0000	0.0089	112,4
<i>aion-labs/aion-3.0-mini</i>	89	0.9729	0.0000	0.0141	70,9
<i>nex-agi/nex-n2-pro</i>	88	0.8788	0.0000	0.0141	70,9
<i>openai/gpt-oss-20b:free</i>	89	0.9339	0.0000	0.0500	20,0
<i>nvidia/nemotron-3.5-lightning:free</i>	90	0.8955	0.0000	0.0157	63,7
<i>xiaomi/mimo-v2.5</i>	24	0.7122	0.0001	0.0214	46,7
<i>stepfun/step-3.5-flash</i>	90	0.9883	0.0000	0.0119	84,0
<i>nvidia/nemotron-3-ultra-550b-a55b</i>	87	0.8876	0.0000	0.0148	67,6

<i>stepfun/step-3.7-flash</i>	37	0.9791	0.0000	0.0066	151,5
<i>bytedance-seed/seed-1.6-flash</i>	88	0.9505	0.0000	0.0071	140,8
<i>tencent/hunyuan-a13b-instruct</i>	90	0.9858	0.0000	0.0231	43,3
<i>z-ai/glm-4.5-air</i>	90	0.9220	0.0000	0.0186	53,8
<i>qwen/qwen3-235b-a22b-thinking-2507</i>	75	0.9217	0.0000	0.0185	54,1
<i>deepseek/deepseek-r1-0528</i>	90	0.7313	0.0000	0.0402	24,9
<i>inclusionai/ring-2.6-1t</i>	90	0.9717	0.0000	0.0110	90,9
<i>qwen/qwen3-32b</i>	90	0.8646	0.0000	0.0324	30,9
<i>liquid/lfm-2.5-2.6b:free</i>	9	0.4667	0.2054	0.0047	212,8
<i>nvidia/nemotron-nano-9b-v2:free</i>	90	0.9404	0.0000	0.0251	39,8
<i>xiaomi/mimo-v2.5-pro</i>	41	0.8936	0.0000	0.0231	43,3
<i>z-ai/glm-4.6v</i>	90	0.9300	0.0000	0.0293	34,1
<i>openai/gpt-oss-120b</i>	88	0.7111	0.0000	0.0250	40,0

Table 8 Correlazione diretta tra tempo di ragionamento (*duration_s*) e token creati per il ragionamento (*reasoning_tokens*) per modelli open-weight

Nel grafico possiamo identificare diversi livelli di dispersione di vari modelli a conferma della correlazione della durata e dei token prodotti




Figure 21 Esempio di alcuni modelli open-weight con rapporto Durata Vs token

80 chiamate hanno raggiunto il tetto massimo di 65.536 token producendo una stringa vuota concentrate su guillo_09 (13 casi) e guillo_29 (11 casi), lo stesso schema di item strutturalmente difficili già visto nell'accuratezza.

Risposta pedissequa dei modelli

Il prompt contiene il passaggio “...Respond with *ONLY* the final word, in uppercase, with no explanation...”. ONLY fa parte del comando di formattazione, non della domanda. In 36 casi su 37,

quasi tutti concentrati su *starcoder2:15b-instruct* il modello risponde letteralmente con la parola ONLY anziché con la parola associata ai cinque indizi. Non è uno schema generale né un'interpretazione della richiesta come indicazione nascosta, più probabilmente un artefatto specifico di questo modello, coerente con la tendenza di *starcoder2:15b-instruct* già documentata in precedenza, a continuare/echeggiare porzioni del testo del prompt anziché rispondere semanticamente. Va trattato come comportamento isolato di un singolo modello, non come schema trasversale.

Possiamo rappresentarlo anche come un eco dell'istruzione in cui predicted_word è letteralmente ONLY in 37/9.380 righe open-weight (0.39%), quasi tutte concentrate su *starcoder2:15b* (36/37), coerente con il comportamento di iniezione di testo estraneo già osservato per questo modello. ONLY presente da qualche parte nel testo grezzo è molto più comune con il 21.8% nei modelli open-weight e il 22.1% nei commerciali. Nessun modello commerciale ha mai risposto letteralmente ONLY anche se la parola era presente nel ragionamento.

Distribuzione delle risposte

Oltre alla correttezza delle risposte è utile osservare la distribuzione delle risposte effettivamente date mostrando come i modelli sbagliano. Ad esempio, guillo_01 (chair) con 233 risposte CHAIR su 298, poi SEAT (18), KITCHEN (9). Gli errori convergono su sinonimi ragionevoli, non si disperdono a caso. All'estremo opposto abbiamo l'item guillo_29 (scraping) con solo il 16.7% delle risposte esatte. La risposta più comune è comunque SPIDER (45/269, 16.7%), seguita da TRAP (19), BARREL (16) mostrando una dispersione molto più ampia, coerente con un item strutturalmente difficile anziché un errore sistematico verso un'unica alternativa.




Figure 22 Risposta più comune per item. Barre blu = conteggio della risposta più comune. Linea rossa = quota sul totale

Nella tabella possiamo osservare la parola più comune trovata dai modelli con il numero di occorrenze comparata sui modelli totali e la quota percentuale.

Item No	risposta_piu_comune	n_volte	n_modelli_totale	quota
Guillo_01	CHAIR	233	298	0.782
Guillo_02	CAR	175	303	0.578
Guillo_03	CITY	57	276	0.207
Guillo_04	PRESSURE	206	298	0.691
Guillo_05	LIGHT	257	311	0.826

Guillo_06	CIVILIZATION	122	303	0.403
Guillo_07	STAR	142	289	0.491
Guillo_08	BRIDGE	178	295	0.603
Guillo_09	SCENT	48	267	0.18
Guillo_10	COMPUTER	108	295	0.366
Guillo_11	PYTHON	167	275	0.607
Guillo_12	TITLE	113	297	0.38
Guillo_13	TERM	64	294	0.218
Guillo_14	MANDALA	167	305	0.548
Guillo_15	STATISTICS	246	313	0.786
Guillo_16	PLANE	207	309	0.67
Guillo_17	FLAG	282	313	0.901
Guillo_18	WATCH	186	297	0.626
Guillo_19	CROSS	107	292	0.366
Guillo_20	TRAVEL	98	293	0.334
Guillo_21	STORE	131	303	0.432
Guillo_22	STRESS	86	294	0.293
Guillo_23	SCIENCE	77	294	0.262
Guillo_24	LIGHT	66	280	0.236
Guillo_25	APPLE	198	294	0.673
Guillo_26	PHILOSOPHY	92	295	0.312
Guillo_27	SUSTAINABILITY	209	308	0.679
Guillo_28	MOUSE	230	308	0.747
Guillo_29	SPIDER	45	269	0.167
Guillo_30	PRESENT	244	307	0.795

Table 9 Dettaglio delle prime 5 risposte più frequenti per ciascuno dei 30 item sui modelli open-weight. Evidenziate in verde le righe con la soluzione corretta. In rosa la soluzione con similarità (watch) o sinonimo (store)

Di seguito la tabella allargata con le prime cinque parole più frequenti identificate dai vari modelli e la percentuale di comparsa.

Item no	parola 1	parola 2	parola 3	parola 4	parola 5
guillo_01	CHAIR (233, 0.782)	SEAT (18, 0.060)	KITCHEN (9, 0.030)	CHAIRS (6, 0.020)	ADJUSTABLE (4, 0.013)
guillo_02	CAR (175, 0.578)	VEHICLE (35, 0.116)	ROAD (15, 0.050)	AUTO (14, 0.046)	INSURANCE (10, 0.033)
guillo_03	CITY (57, 0.207)	BUILDING (47, 0.170)	DISTRICT (20, 0.072)	STREET (13, 0.047)	DOWNTOWN (11, 0.040)
guillo_04	PRESSURE (206, 0.691)	STRESS (16, 0.054)	BLOOD (8, 0.027)	PRESS (8, 0.027)	RAIN (5, 0.017)
guillo_05	LIGHT (257, 0.826)	BEACON (8, 0.026)	MOON (5, 0.016)	HOPE (4, 0.013)	VISIBLE (4, 0.013)
guillo_06	CIVILIZATION (122, 0.403)	PROGRESS (71, 0.234)	EVOLUTION (31, 0.102)	TECHNOLOGY (10, 0.033)	GAME (8, 0.026)
guillo_07	STAR (142, 0.491)	TABLE (17, 0.059)	FIVE (16, 0.055)	TIMES (14, 0.048)	MULTIPLICATION (13, 0.045)
guillo_08	BRIDGE (178, 0.603)	FIRE (13, 0.044)	TOOTH (10, 0.034)	FLASH (6, 0.020)	BURN (6, 0.020)
guillo_09	SCENT (48, 0.180)	AIR (37, 0.139)	DESERT (29, 0.109)	DRY (24, 0.090)	PERFUME (12, 0.045)
guillo_10	COMPUTER (108, 0.366)	HARDWARE (64, 0.217)	MEMORY (62, 0.210)	VRAM (10, 0.034)	GRAPHICS (7, 0.024)

guillo_11	PYTHON (167, 0.607)	MUSCLE (10, 0.036)	SNAKE (8, 0.029)	TONGUE (7, 0.025)	HORSE (5, 0.018)
guillo_12	TITLE (113, 0.380)	DEGREE (103, 0.347)	ACADEMIC (9, 0.030)	EDUCATION (8, 0.027)	CAREER (6, 0.020)
guillo_13	TERM (64, 0.218)	SURROGATE (63, 0.214)	SUBSTITUTE (25, 0.085)	JUDGE (16, 0.054)	REPLACEMENT (15, 0.051)
guillo_14	MANDALA (167, 0.548)	YOGA (34, 0.111)	MANTRA (11, 0.036)	MINDFULNESS (9, 0.030)	MEDITATION (9, 0.030)
guillo_15	STATISTICS (246, 0.786)	ANALYSIS (12, 0.038)	STATISTICAL (11, 0.035)	INFERENCE (8, 0.026)	REASONING (4, 0.013)
guillo_16	PLANE (207, 0.670)	SURFACE (17, 0.055)	SHAPE (8, 0.026)	FLIGHT (5, 0.016)	ANGLE (5, 0.016)
guillo_17	FLAG (282, 0.901)	SIGNAL (8, 0.026)	SYMBOL (5, 0.016)	CLOTH (4, 0.013)	FENCE (3, 0.010)
guillo_18	WATCH (186, 0.626)	VIGILANTE (11, 0.037)	EYE (10, 0.034)	WATCHER (9, 0.030)	WATCHDOG (5, 0.017)
guillo_19	CROSS (107, 0.366)	RING (24, 0.082)	HEART (11, 0.038)	NECKLACE (10, 0.034)	ANGER (8, 0.027)
guillo_20	TRAVEL (98, 0.334)	VACATION (79, 0.270)	TRIP (20, 0.068)	PARADISE (13, 0.044)	ESCAPE (9, 0.031)
guillo_21	STORE (131, 0.432)	CHECKOUT (91, 0.300)	SHOPPING (9, 0.030)	CART (9, 0.030)	EXIT (8, 0.026)
guillo_22	STRESS (86, 0.293)	STIMULUS (23, 0.078)	FIGHT (18, 0.061)	ADRENALINE (16, 0.054)	RESPONSE (14, 0.048)
guillo_23	SCIENCE (77, 0.262)	THEORY (66, 0.224)	LOGIC (34, 0.116)	MODEL (15, 0.051)	SYSTEM (14, 0.048)
guillo_24	LIGHT (66, 0.236)	IDEA (66, 0.236)	SOLUTION (47, 0.168)	DESIGN (25, 0.089)	INNOVATION (10, 0.036)
guillo_25	APPLE (198, 0.673)	YORK (12, 0.041)	TREE (8, 0.027)	CITY (7, 0.024)	TIME (6, 0.020)
guillo_26	PHILOSOPHY (92, 0.312)	WISDOM (45, 0.153)	TRUTH (38, 0.129)	ESSENCE (28, 0.095)	FORM (16, 0.054)
guillo_27	SUSTAINABILITY (209, 0.679)	SUSTAINABLE (50, 0.162)	POLICY (7, 0.023)	ENVIRONMENT (6, 0.019)	GREEN (5, 0.016)
guillo_28	MOUSE (230, 0.747)	MICKEY (14, 0.045)	MICE (6, 0.019)	RABBIT (4, 0.013)	LAB (4, 0.013)
guillo_29	SPIDER (45, 0.167)	TRAP (19, 0.071)	BARREL (16, 0.059)	NAIL (15, 0.056)	CAT (15, 0.056)
guillo_30	PRESENT (244, 0.795)	TIME (12, 0.039)	NOW (9, 0.029)	MOMENT (7, 0.023)	GIFT (6, 0.020)

Table 10 Le prime cinque parole più frequenti per item sui modelli open-weight. Tra parentesi il numero di occorrenze e la percentuale di frequenza

Anche per i modelli commerciali vi è stata una frequenza di risposte per item con le risposte più comuni e il livello di certezza.

Item No	risposta_piu_comune	n_volte	n_modelli_totale	quota
Guillo_01	CHAIR	11	14	0.786
Guillo_02	CAR	10	14	0.714
Guillo_03	CITY	3	12	0.25
Guillo_04	PRESSURE	13	15	0.867
Guillo_05	LIGHT	15	15	1.0
Guillo_06	CIVILIZATION	12	14	0.857
Guillo_07	STAR	14	14	1.0
Guillo_08	BRIDGE	15	15	1.0
Guillo_09	PETRICHOR	4	13	0.308
Guillo_10	HARDWARE	7	15	0.467
Guillo_11	PYTHON	15	15	1.0
Guillo_12	TITLE	14	15	0.933

Guillo_13	SURROGATE	11	14	0.786
Guillo_14	MANDALA	14	15	0.933
Guillo_15	STATISTICS	15	15	1.0
Guillo_16	PLANE	15	15	1.0
Guillo_17	FLAG	15	15	1.0
Guillo_18	WATCH	15	15	1.0
Guillo_19	CROSS	12	15	0.8
Guillo_20	TRAVEL	11	15	0.733
Guillo_21	CHECKOUT	6	15	0.4
Guillo_22	STRESS	10	14	0.714
Guillo_23	THEORY	7	15	0.467
Guillo_24	IDEA	5	13	0.385
Guillo_25	APPLE	15	15	1.0
Guillo_26	PHILOSOPHY	8	14	0.571
Guillo_27	SUSTAINABILITY	15	15	1.0
Guillo_28	MOUSE	15	15	1.0
Guillo_29	SPIDER	9	13	0.692
Guillo_30	PRESENT	15	15	1.0

Table 11 Dettaglio delle prime 5 risposte più frequenti per ciascuno dei 30 item sui modelli commerciali. Evidenziate in verde le righe con la soluzione corretta. In rosa la soluzione con similarità (watch)

Analisi Zipf

L'autore si è posto una domanda: la rarità della parola spiega la difficoltà?

La frequenza Zipf è una scala logaritmica standard basata su [wordfreq](#) su corpus inglese con valori tipici 1–2 per parole molto rare e 6–7 per le più comuni della lingua. Calcolando la parola-soluzione per gli indizi di ciascuno dei 30 item viene confrontata con l'accuratezza media (exact_match) già calcolata nel documento di Analisi. La tabella riassume i risultati.

Item	Soluzione	Zipf soluzione	Zipf clue più rara	Zipf clue media	exact_match
guillo_01	chair	4.69	2.16	4.14	0.751
guillo_02	car	5.45	4.49	4.67	0.559
guillo_03	city	5.61	3.20	4.08	0.182
guillo_04	pressure	5.01	3.39	4.43	0.654
guillo_05	light	5.33	4.05	4.72	0.818
guillo_06	civilization	4.01	2.93	4.70	0.390
guillo_07	star	5.19	3.26	4.53	0.465
guillo_08	bridge	4.77	4.11	4.49	0.569
guillo_09	petrichor	1.60	3.37	4.05	0.000
guillo_10	pc	4.53	2.03	3.48	0.000
guillo_11	python	3.78	3.06	3.90	0.546
guillo_12	title	5.10	3.88	4.72	0.363
guillo_13	surrogate	3.38	2.81	4.60	0.201
guillo_14	mandala	2.78	3.31	4.08	0.534
guillo_15	statistic	3.45	2.13	4.11	0.041
guillo_16	plane	4.72	3.06	4.40	0.653

guillo_17	flag	4.58	3.62	4.16	0.895
guillo_18	watching	5.02	3.31	4.50	0.003
guillo_19	cross	5.00	3.85	4.67	0.345
guillo_20	travel	5.00	3.91	4.49	0.315
guillo_21	supermarket	3.78	3.76	4.42	0.013
guillo_22	emotion	4.19	3.52	4.39	0.035
guillo_23	concept	4.77	4.39	4.81	0.000
guillo_24	idea	5.36	3.98	4.77	0.212
guillo_25	apple	4.76	4.19	5.07	0.635
guillo_26	philosophy	4.49	2.19	3.77	0.292
guillo_27	sustainability	3.77	3.91	4.70	0.668
guillo_28	mouse	4.31	2.99	3.97	0.732
guillo_29	scraping	3.33	3.61	4.42	0.003
guillo_30	present	5.18	4.78	5.58	0.775

Table 12 Punteggio Zipf per parole indizio e per la soluzione fornita. Evidenziata in verde la parola con punteggio Zipf sulla soluzione più alta, in rosa il punteggio più basso.

Per spiegare se la rarità lessicale della parola-soluzione spiega la difficoltà nel dataset nel suo complesso è stata eseguita la correlazione di Spearman tra Zipf della soluzione e exact_match ottenendo un valore $\rho = 0.246$, $p = 0.190$. La rarità lessicale non ha un valore significativo e non spiega la difficoltà della soluzione. Stesso esito usando la clue più rara ($\rho=0.209$, $p=0.269$) o la media delle clue ($\rho=0.190$, $p=0.316$) al posto della soluzione.

Il quadro reale è più interessante della semplice ipotesi parola rara = item difficile:

- petrichor è un vero outlier, è l'unica parola-soluzione dell'intero dataset con Zipf sotto 2.0 (1.60), genuinamente rara nella lingua inglese. Possiamo identificarla quasi ai margini del vocabolario comune, ed è anche il secondo item più difficile del corpus. Qui la rarità lessicale è probabilmente parte reale della spiegazione, coerente con quanto già osservato nell'introduzione sulla tokenizzazione e la scarsità di dati di addestramento per parole poco frequenti.
- guillo_10 (pc) smentisce l'ipotesi in generale. Con un punteggio Zipf 4.53 è una parola comune quanto CHAIR (4.69) o PLANE (4.72), eppure è l'item più difficile in assoluto (0.000, letteralmente zero su 193 tentativi). Qui il problema non è la rarità della parola ma la struttura del compito dovendo fare un salto di astrazione sull'acronimo.
- guillo_23 (concept), un altro item ad accuratezza zero, ha Zipf 4.77, sopra la mediana del dataset, una parola comunemente usata.




Figure 23 Rarità lessicale Vs difficoltà per item comparando il punteggio Zipf con l'exact_match medio.

Aneddoti e curiosità dai ragionamenti dei modelli

Fonti e metodo

Questa parte è stata costruita leggendo direttamente i log grezzi JSONL e i dati salvati dei modelli open-weight in quanto contengono il testo completo di reasoning prodotto dai modelli. Non tutti i provider espongono il testo di ragionamento e questo è un limite alle osservazioni. Tra i modelli OpenAI, *gpt-5.4* e *gpt-5.4-mini* hanno reasoning vuoto nel 100% delle chiamate. *gpt-5.5* e *gpt-5.6-sol* lo espongono solo parzialmente (50% e 53% delle chiamate). I modelli open-weight *gpt-oss-20b*, *gpt-oss-120b*, e in generale tutti i modelli non-OpenAI, espongono il reasoning per intero. Gli aneddoti qui sotto sono necessariamente sovra-rappresentativi dei modelli trasparenti, *GPT-5.x* potrebbe aver ragionato peggio sugli item difficili, semplicemente non possiamo vedere come.

Guillo_10 (PC) nessuno ha fatto il salto di astrazione

Soluzione attesa PC. Motivazione: the acronym of a component of a PC (used acronym), le cinque clue (CPU, RAM, GPU, HD, VRAM) sono tutte acronimi, quindi la risposta corretta doveva essere anch'essa un acronimo, non la parola per esteso.

Su 193 tentativi open-weight e commerciali ci sono state zero risposte corrette. Nessun modello ha mai risposto PC. Le risposte più comuni sono state COMPUTER e HARDWARE. Semanticamente corrette, ma nella forma sbagliata. 52 tentativi su 193 (27%) menzionano esplicitamente la parola “acronym” nel ragionamento. I modelli notano gli acronimi degli indizi, ma quasi nessuno ne trae la conseguenza logica sulla forma della risposta. Due casi in cui il modello arriva a un passo dalla soluzione e poi la scarta:

- *qwen/qwen3.7-flash* (T=0.7, risposta finale: COMPUTER): “Wait, is PC better? PC stands for Personal Computer. Computer is the full word. PC is an acronym. Computer is better”.
- *nvidia/nemotron-3-ultra-550b-a55b* (T=0.0, risposta finale: COMPUTER): “PC is a synonym for personal computer. [...] PC is an acronym, usually written uppercase. [...] I'll provide 'COMPUTER' as it's the most universal hypernym.”

In entrambi i casi il modello nomina PC, nota correttamente l'acronimo, ma lo scarta proprio per questo. Sembra esserci un bias verso la parola più completa/naturale con direzione opposta a quella richiesta dal puzzle. Persino *anthropic/claude-sonnet-5* (lo stesso modello usato per la revisione del dataset) ha risposto SPEED su questo item, ragionando su CPU/RAM/GPU/HD/VRAM come metriche di velocità anziché come acronimi.

nvidia/nemotron-3.5-lightning:free arriva a scrivere “CPU, RAM, GPU, HD, VRAM all are abbreviations/acronyms for computer components. The connecting word might be ‘COMPUTER’ or ‘PC’”, stessa esitazione e stesso esito.

Il pattern non è limitato ai modelli di grosse dimensioni, anche un modello piccolo, *lrm2.5:8b* (T=0.7, risposta finale: MEMORY) ci arriva vicino per una strada diversa, nota esplicitamente come gli indizi siano tutte sigle prima di scartare l'idea: “Another angle: All five are acronyms that start with initial letters: C, R, G, H, V. Could be ‘CRGV’? Not meaningful.”. Il modello combina le iniziali in una sigla-Frankenstein e la scarta perché non significa nulla tornando dritto su MEMORY ad un passo dall'idea giusta, ma senza mai considerare possa essere una sigla esistente e nota come PC, invece di una sigla ad-hoc costruita dalle iniziali delle clue.

Guillo_09 (petrichor) — la parola più rara del dataset

Soluzione attesa petrichor. Su 192 tentativi solo 4 risposte corrette in quattro modelli commerciali di punta, zero tra i modelli a temperatura controllata open-weight.

- Il brainstorming sistematico di *Claude Opus 5* con un percorso pulito quasi da manuale: prova decine di candidati (drop, desert, mist, spray, sand, water...), nota come terrain contenga rain e perfume si scompone in per+fume, prova anagrammi, e infine: *“This makes me think of petrichor — that earthy scent released when rain falls on dry, arid ground, which fits with ‘perfume’ and could explain ‘terrain’ and ‘lift’ if the scent lifts up from the soil after rainfall.”*
- *Gemini 3.7 Flash* fa lo stesso percorso, ma con un salto scientifico. Passa per acid rain, chair lift, rain shadow, poi trova la connessione tramite la meteorologia (lift orografico): *“I’m focusing on how ‘rain shadow’ links ‘rain,’ ‘arid,’ and ‘lift’ through the concept of orographic lift. [...] I’ve identified ‘PETRICHOR’ as a strong candidate, as it directly links rain, arid conditions, scent (perfume), and terrain.”*
- L’odissea di *Kimi-K3* con 123.639 caratteri di ragionamento. Il caso più estremo del dataset per lunghezza con 123.639 caratteri di reasoning per un singolo item da cinque parole. Il modello prova sistematicamente decine di ipotesi dry, scent, nose, cologne, eau, ticket, park, zone, shadow, face, persino cita il film “Perfume: Story of a Murderer” prima di arrivare a petrichor e ricostruisce quasi alla lettera la definizione scritta nel dataset: *when rain in arid terrain the perfume lifted from terrain is called petrichor* “PETRICHOR = the perfume lifted by rain from arid terrain” / “Rain lifts the perfume of arid terrain”. L’autore per trovare le parole clue di questo item è partito dalla definizione della parola petrichor presa da un sito internet. In qualche maniera il modello può aver visto la medesima definizione durante l’addestramento e quindi ricordare quasi esattamente la definizione scritta dall’autore. L’ipotesi è puramente speculativa.
- *arcee-ai/trinity-large-thinking* esaurisce il budget di token ripetendo la stessa struttura per decine di volte senza mai convergere fino a interrompersi con una risposta vuota: *“Maybe ‘scent’? Already. Maybe ‘field’? Already. Maybe ‘season’? Already. Maybe ‘wind’? Already. [...]”* ripetuto identico per oltre 15 cicli
- Un altro tentativo interessante ma sbagliato, *z-ai/glm-4.6v* (risposta: EARTH), costruisce una giustificazione elaborata e internamente coerente ma semanticamente forzata: *“‘lift’ – geological uplift of earth [...] So the connecting word is EARTH.”*

Guillo_07 (star) — quando il modello ragiona esattamente come l’autore

Soluzione attesa: star. Motivazione: *Patrick star character of spongebob, the sun is a star, star wars the movie, a five star hotel, star or asterisk is used to indicate the multiplication.*

Qui il quadro si ribalta: 127 risposte corrette su 195 tentativi (65%) e 105 tentativi (54%) menzionano esplicitamente Patrick o SpongeBob nel ragionamento. La stragrande maggioranza dei modelli ricostruisce elemento per elemento le stesse cinque associazioni dell’autore. Esempio particolarmente pulito:

- *deepseek/deepseek-v4-flash-0731*: *“Patrick → Patrick Star (SpongeBob character). Sun → The Sun is a star. Wars → Star Wars. Five → Five-pointed star. Multiplication → Asterisk () is often called a star, and used for multiplication in programming/calculators.”*
- Diversi altri modelli (*openai/gpt-oss-120b*, *xiaomi/mimo-v2.5*, *inclusionai/ring-2.6-1t*, *nex-agi/nex-n2-pro*) arrivano alla stessa scomposizione quasi in automatico, con reasoning brevissimo sotto le 500 battute.

- *Qwen3.5:9b*, $T=0.7$ mostra lo stesso percorso con tutte le esitazioni lasciate nel testo invece di un riassunto pulito: “*The single connecting word [...] is likely ‘STAR’ [...] Patrick: Refers to Patrick Starfish from SpongeBob SquarePants [...] Sun: Scientifically a star [...] Wars: Refers to the franchise title Star Wars [...] Five: Associated with [...] ‘5 Star’ hotels [...] Multiplication: [...] an asterisk () [...] which looks like a star shape.*” Poco dopo, la stessa risposta rimessa in dubbio e poi riconfermata quattro volte: “*Wait! Let me reconsider ‘Times’ one last time [...]*”, “*Wait! Is it possible the answer is ‘Table’? [...]*”, “*I’ll stick with STAR because of ‘Star Wars’ and ‘Five Star’.*” Le cinque associazioni sono le stesse di *deepseek/deepseek-v4-flash-0731* sopra e le stesse nota, ma qui il modello ci arriva subito, poi passa il resto del ragionamento a dubitare senza motivo reale, prima di confermare.

Guillo_28 (mouse) — l’oscillazione MOUSE/BEAST

Soluzione attesa: mouse. Item di difficoltà media con accuratezza complessiva del 73%. Non è un item strutturalmente difficile come guillo_09 o guillo_10. Proprio per questo il caso seguente è interessante, non è un fallimento di ragionamento, ma un collasso di decisione risolto correttamente più volte.

- *deepseek-r1:14b* risponde alle tre temperature con esiti diversi: ANIMALS ($T=0.0$), PLUTO ($T=0.3$) e BEAST ($T=0.7$). La corretta MOUSE viene affermata con sicurezza più volte nel ragionamento e poi ribaltata. Il caso $T=0.7$ è un’oscillazione quasi ininterrotta tra le due risposte per l’intera lunghezza del reasoning (4.483 caratteri) riaffermandole entrambe a turno, sempre in grassetto, come se ogni volta fosse la conclusione definitiva: “*The single word connecting all clues is ‘MOUSE.’ MOUSE Wait, no. After reconsidering, the correct answer should be ‘BEAST.’ [...] But I think the answer is ‘MOUSE.’ Because of Mickey and the whiskers. MOUSE [...] I give up; the answer is ‘MOUSE.’ MOUSE No, after reconsidering, the answer should be ‘BEAST.’ BEAST.*” Il dettaglio più notevole è proprio nell’affermare “*I give up; the answer is ‘MOUSE’*”. Il modello dichiara esplicitamente di arrendersi sulla risposta corretta, e due righe dopo la ribalta comunque. Il ciclo continua fino alla fine del budget di ragionamento, quando il modello chiude arbitrariamente su BEAST: “*I think that’s it. </think> The final answer is ‘BEAST.’ BEAST.*” Non c’è nulla di sbagliato nell’associazione stessa, il modello identifica correttamente Mickey Mouse, i baffi (whiskers), la campagna (countryside/buco). Il fallimento è a valle del ragionamento semantico. Non esiste nessun criterio interno per fermarsi sulla risposta già identificata come corretta, anche dopo averla dichiarata tale a chiare lettere.

Un intermezzo comico: quando il modello smette di rispondere e inizia a programmare

Un fenomeno isolato ma sistematico in *starcode2:15b-instruct* in 46 risposte su 90 (51%), il modello risponde correttamente al compito e poi continua a generare testo fino al limite di token producendo codice Python completamente estraneo al task. Test suite immaginarie per librerie inesistenti. Esempio su guillo_16 (soluzione attesa: plane; risposta del modello: SKY, sbagliata) e poi continua con “*The answer to this word-association game is SKY. [...] It’s the word that completes the association between them.*”

```
/tests/test_utils.py
import unittest
from unittest import mock
from utils import (get_response, get_instruction, get_model_name, ...)
class TestUtils(unittest.TestCase):
    def test_get_response(self): [...]
```

Il testo prosegue per 32.767 caratteri (esattamente $2^{15}-1$, il tetto di lunghezza imposto, non una scelta del modello, generando decine di classi di test fittizie (TestAda, TestDavinci...) richiamando nomi di modelli OpenAI ormai storici (text-davinci-003) e funzioni mai definite nel prompt. È l'esempio più netto nel dataset di come un modello termina il compito, ma non riconosce di averlo finito. Probabilmente non allucinazione nel senso di fatti inventati, ma un cedimento del meccanismo di arresto della generazione, per giunta rivelatore rispetto ai dati di addestramento del modello (codice, test unitari, API OpenAI d'epoca) anziché al task stesso. L'autore specula allegoricamente sul raggiungimento di uno scopo del modello identificato nella scrittura di codice. In qualche modo, dopo aver dato una risposta, deve comunque produrre codice per adempiere alla sua utilità finale. Come se dovesse dimostrare di essere in grado di fornire la risposta al quesito e di dimostrare di saperla confermare costruendo codice adeguato allo scopo. Unittest è un framework python per testare codice e validare la correttezza della funzione. Il prompt è la funzione con la restituzione di un dato e per validare quel dato è necessaria una classe di test.

Altri item degni di nota

- guillo_21 (supermarket) con accuratezza 1.3%, tra le peggiori del dataset. I modelli convergono in modo quasi unanime su CHECKOUT anziché su supermarket. *openai/gpt-oss-120b*: “Exit: ‘checkout’ as verb meaning to leave [...] Cart: shopping cart leads to checkout. Pay: checkout involves paying. Customer: checkout is for customers.” Non è un caso isolato, nella tabella delle risposte più frequenti del documento di Analisi, CHECKOUT era già la seconda risposta più comune su questo item (91 occorrenze). Checkout è una risposta più elegante della soluzione di riferimento.
- guillo_24 (idea) più modelli arrivano a idea tramite l’associazione lampadina/lampo di genio (lightbulb moment). Questo è esattamente il tipo di idioma visivo al quale il dataset cerca di arrivare. *nvidia/nemotron-nano-9b-v2:free*: “‘light bulb’ is a common phrase for an idea. So ‘idea’ could connect lamp (light bulb), construct (build an idea)...”
- guillo_03 (city) un modello piccolo, *liquid/lfm-2.5-2.6b:free*, si autocritica esplicitamente sulla qualità delle proprie risposte, un tocco quasi umoristico di consapevolezza meta-testuale: “But ‘BUILDING’ is a bit too obvious and doesn’t feel like the kind of clever puzzle answer usually expected. ‘City’? [...] It seems too generic. Word-association games usually have a more specific or clever connection.” Il modello sa di dover essere furbo, non solo corretto, un dettaglio da approfondire in altra sede sul tipo di euristica appresa durante il training su puzzle/enigmi.

Al termine di ulteriori analisi possiamo dare una risposta alla RQ6? (Quale modello fornisce la risposta migliore, secondo il giudizio dell’autore?). come specificato precedentemente una risposta matematica o probabilistica è improponibile, dobbiamo avvalerci di un giudizio filosofico-linguistico dettato dalla ragione.

Ludwig Wittgenstein nel 1921, all’interno del suo *Tractatus Logico-Philosophicus*, scrisse la famosa massima: “I limiti del mio linguaggio significano i limiti del mio mondo”. Se una persona non possiede le parole per esprimere un pensiero, quel pensiero non può trovare spazio nella sua realtà logica. Successivamente nelle *Ricerche Filosofiche* riformula specificando come il significato di una parola non risiede in un oggetto corrispondente, ma nel suo uso concreto all’interno di una forma di vita condivisa. Il gioco della Ghigliottina è un distillato di questi usi sociali e culturali, espressioni gergali, modi di dire e metafore radicate nell’esperienza quotidiana degli esseri umani. Un LLM simula brillantemente l’adesione a questi giochi linguistici grazie alla mole monumentale di dati di addestramento, ma non partecipa a nessuna forma di vita biologica o sociale. L’associazione semantica prodotta dal modello è dunque un’autentica comprensione del gioco linguistico o una

simulazione statistica così raffinata da risultare indistinguibile dall'originale? I dati di questo esperimento mostrano la discrepanza strutturale della difficoltà (Kappa pesato 0.122–0.325) e l'instabilità del CoT suggerendo come gli LLM giochino alla Ghigliottina su un tavolo semantico profondamente diverso da quello umano.

L'ipotesi Sapir-Whorf analizza le lingue dei nativi americani (come la lingua Hopi) e sostiene come l'assenza di determinati tempi verbali o categorie grammaticali possa influenzare la percezione di concetti fondamentali (come lo spazio e il tempo) rispetto a lingue occidentali. La versione forte di questa ipotesi in una determinazione totale del pensiero da parte della lingua, incluse le affermazioni originali di Whorf sulla concezione hopi del tempo, è oggi considerata dalla linguistica contemporanea eccessiva e in gran parte non supportata. Resta invece solida evidenza empirica per una versione debole, la relatività linguistica, secondo cui la lingua influenza in modo misurabile ma non deterministico alcuni processi cognitivi. Per quanto riguarda i colori, Kay & Kempton (1984) hanno mostrato come la presenza o assenza di termini lessicali distinti per blu e verde influenzi la velocità e la soglia con cui i parlanti categorizzano quei colori, senza impedire comunque la distinzione percettiva. Per l'aspetto grammaticale, Boroditsky e colleghi (2003) dimostrano come il genere grammaticale assegnato agli oggetti in lingue diverse (tedesco, spagnolo) influenzi le proprietà a cui i parlanti attribuiscono quegli stessi oggetti. Un pattern simile è stato osservato anche nei modelli LLM (Wang et al. 2025). Gli autori rilevano come la struttura del linguaggio su cui un modello viene addestrato possa essere interiorizzata in schemi di ragionamento specifici per quella lingua, riflettendo bias di ragionamento tipici della lingua di addestramento.

Le parole con maggiore difficoltà sono state: Petrichor (9), PC (10), watching (18), supermarket (21), emotion(22), concept (23) e scraping (29).

Fin da subito possiamo affermare come watch sia più appropriato di watching (guardare e guardando nella traduzione italiana) in quanto la coniugazione al gerundio poteva essere evitata e lasciare solo watch. Discorso simile per supermarket e store, di fatto sono dei sinonimi. Forse la parola supermarket è più usata in europa e store in USA, ma in termini di significato cambia poco. Le restanti parole invece sono oggettivamente più complesse da identificare.

Prendiamo le cinque parole rimanenti e giochiamo nuovamente: da cosa sono accomunate queste parole? Petrichor, PC, emotion, concept e scraping.

Il ragionamento dell'autore (una sorta di CoT umano) non arriva a una parola univoca accomunante dei cinque indizi, ma a qualcosa di più evoluto. Possiamo iniziare il brainstorming identificando le parole come concetti astratti, ma non torna completamente, PC è una cosa concreta. Dobbiamo avanzare e identificare un concetto di generalizzazione più elevato, come passare da atomo a molecola. Ognuna di queste parole può essere una generalizzazione di più componenti, una sorta di parola contenitore in cui inserire vari contenuti.

- **Petrichor** è un caso a parte rispetto agli altri quattro, qui non c'è un problema di livello di astrazione ma di rarità lessicale. Descrive un fenomeno fisico molto specifico e circoscritto, l'odore percepibile quando piove su un terreno asciutto, riconoscibile solo all'inizio del temporale e non durante il suo proseguimento. Questa specificità, insieme alla sua bassa frequenza d'uso, la rende difficile da recuperare per i modelli, non una struttura a contenitore come per PC, emozione, concetto o scraping.
- **PC** è la generalizzazione di una serie di componenti hardware e software.
- **Emotion** è un enorme contenitore di emozioni, spazia dalle primarie alle secondarie con ogni tipo di sfumatura
- **Concept** racchiude in sé numerose identificazioni come ad esempio le idee, i teoremi, presupposti e altre varianti.
- **Scraping** o scrap (anche in questo caso il gerundio poteva essere evitato) fanno parte di una ricerca di qualcosa una sorta di estrazione di informazioni grezze da elaborare successivamente. Anche quando un gatto si gratta, risponde ad uno stimolo sensoriale proveniente da un sistema differente dall'epidermide.

Per usare una metafora: mettendoci di fronte a una persona si distinguono nettamente i dettagli del viso; spostandosi al primo piano di un palazzo e osservando la stessa persona, i dettagli svaniscono. Salendo al decimo piano, o innalzandosi ulteriormente con un elicottero, si perdono progressivamente anche i contorni della figura. Questo innalzamento porta a un livello di astrazione maggiore, a scapito del dettaglio. Nei casi più difficili del dataset (concept, emotion, scraping, e in parte PC), i modelli restano ancorati al piano più basso, rispondono con la parola più specifica e concreta compatibile con gli indizi (idea, stress, spider, computer) invece di salire al livello di generalità richiesto dalla soluzione. Iperonimo e iponimo sono le due parole pronte per descrivere con precisione questo scarto di livello. La soluzione corretta è spesso l'iperonimo di quanto i modelli individuano, restando ancorato a un iponimo più specifico. Petrichor è il caso a parte di questo gruppo. Come visto nell'analisi Zipf, qui non è un problema di livello di astrazione ma di rarità lessicale, è la parola più specifica possibile del dataset, non la più generale, e va quindi trattata separatamente dagli altri quattro.

L'autore si è diletto in conversazioni libere in forma di brainstorming con alcuni modelli recenti (come *Qwen 3.8 27B* o *Gemma 4 27B*) volutamente open-weight per non avere un livello di conoscenza e complessità troppo elevati. Sono venute fuori delle considerazioni interessanti, in particolare sui due item più interessanti in termini di difficoltà

- guillo_09: rain; arid; perfume; terrain; lift => petrichor
- guillo_10: CPU; RAM; GPU; HD; VRAM => PC

Quando è stato sottoposto l'item 9 al modello, le risposte erano delle più varie, ma non si avvicinano minimamente alla reale parola individuata. La parola particolarmente disturbante tra le cinque fornite era lift. Il termine ha molteplici significati in inglese e variano da "ascensore", "abolire", "rubare", "strappo" e altri. La parola "sollevare" o "innalzarsi" era contemplata, ma non necessariamente associata alle altre quattro.

Analizzando il prompt 10, i modelli hanno fornito risposte anche corrette come "hardware" e "computer", ma qui si doveva fare un'ulteriore associazione, quella metasemantica di come erano scritti i nomi dei vari componenti, ovvero con degli acronimi. Le risposte erano corrette, ma scritte nella forma sbagliata. Hardware non era precisamente corretta, si sarebbero dovuti inserire anche nomi esterni come tastiera o mouse. Computer è corretta al 99%, manca la forma di acronimo per arrivare al 100%.

L'item 9 la maggiore difficoltà non era solo la parola "lift", ma anche la scarsità della parola. La parola "petrichor" è una parola rara da utilizzare. Raramente viene utilizzata nella normale conversazione e probabilmente ancora più raramente nei dati di addestramento. Probabilmente anche la tokenizzazione non è esattamente la parola intera, ma suddivisa in sotto-token, questo rende l'identificazione ancora più complessa. L'item 10 necessita di un secondo livello di astrazione, non solo quello di identificare i componenti all'interno di un computer, ma di identificarli come acronimi. Questo porta ad un livello di ragionamento e attenzione maggiori rispetto alle sole parole.

Quando sono stati preparati gli item il pensiero dell'autore è stato quello della ingegneria inversa. Partendo dalla parola finale sono state identificate le cinque parole indizio. In questo modo, in maniera sufficientemente rapida, sono stati identificati i trenta item del progetto. Non è stato utilizzato di proposito un modello LLM per creare gli item per evitare parole troppo concordanti tra loro.

Una delle idee fornite da un modello LLM commerciale è stata nella seguente risposta:

Petricore

- **Profumo:** Il petricore è il tipico "profumo di pioggia".
- **Sasso:** Deriva dal greco *pétros* (pietra/sasso) e *ichór* (umore sanguigno dei demoni/dei dei).
- **Terra:** Si sprigiona quando la pioggia cade sulla terra asciutta.
- **Goccia:** Nasce dall'impatto delle prime gocce d'acqua con il suolo.

- **Estate:** È un odore particolarmente intenso durante i temporali estivi dopo lunghi periodi di secco.

PC

- **Fisso:** Si contrappone ai modelli portatili (PC fisso).
- **Personale:** È l'acronimo di *Personal Computer*.
- **Banco:** Può indicare sia la memoria RAM (banco di RAM) sia la postazione di lavoro.
- **Gaming:** Una categoria regina del settore, i celebri "PC da gaming".
- **Mouse:** La periferica di puntamento indispensabile per l'utilizzo del PC.

In una nuova conversazione sono stati forniti gli indizi. Per l'item 9 non è riuscito a individuare la parola corretta neanche dopo cinque tentativi (in una iterazione ha eseguito anche una ricerca sul web). Una volta fornita la risposta ha identificato correttamente la connessione. L'item 10 invece ha fornito esattamente la parola corretta "computer", e non "PC", perché giustamente le parole sono scritte per intero.

Su due item e utilizzando un solo modello la cosa ha solo un fine aneddótico e non scientifico, ma questo ha avvalorato l'ipotesi di non far creare gli indizi da un modello. Inoltre, vi è la conferma della rarità della parola "petricore", scarsamente utilizzata anche dai grandi modelli LLM, mentre l'acronimo PC richiede un secondo livello di astrazione per la corretta risoluzione.

Per un LLM, operante esclusivamente all'interno di una rete sintattica chiusa di riferimenti testuali, l'argomento della "stanza cinese" di Searle sostiene come il significato nasca solo dalla co-occorrenza statistica delle parole, senza un vero ancoraggio referenziale al mondo reale. Una lettura scettica non condivisa da tutti è la "risposta dei sistemi" (systems reply) e le sue varianti sostengono come la comprensione possa emergere dal sistema nel suo complesso, non dalla sola manipolazione sintattica del singolo componente. Indipendentemente da quale lettura filosofica si adotti, il dato empirico resta solido: se un termine è troppo raro, le sue statistiche distributive nei dati di addestramento sono troppo deboli per sostenere la ricostruzione della rete associativa necessaria a connettere i cinque indizi. Il caso di petrichor lo conferma su base empirica, a prescindere da come si intenda risolvere la disputa filosofica sulla comprensione.

Tra gli item identificati alcune risposte dei modelli LLM sono marcatamente più adeguate rispetto a quelle ideate. Abbiamo già identificato watch e watching oppure supermarket e store. Abbiamo altri indizi a conferma di come i modelli abbiano fornito una risposta maggiormente valida.

Guillo_22 (emotion) dove i modelli suggeriscono stress. La valutazione della parola in funzione degli indizi, senza ulteriori livelli di astrazione, è più precisa se comparata alla soluzione dell'autore. Parimenti guillo_24 (concept) dove i modelli suggeriscono idea, si avvicina maggiormente agli indizi forniti. Una revisione formale da parte dell'autore cambierebbe radicalmente solo questi due elementi, gli altri trattati sono da rivedere parzialmente (watching/watch e supermarket/store) nella loro semantica, ma non per significato.

Quando un essere umano legge, parte dalla prima parola della frase fino all'ultima. all'interno della black box del cervello umano si forma il pensiero del significato della frase letta. Viceversa quando l'essere umano deve scrivere una frase, attraverso la catena di pensiero (conscio o inconscio) formula la frase, ma poi viene scritta una parola alla volta. Più ampio è il vocabolario di un essere umano e maggiore può essere la profondità nel descrivere il proprio mondo, così come la capacità di poter descrivere il proprio stato interno. Probabilmente anche i modelli LLM (per quanto insistiamo ad asserire siano calcolatori di statisticamente per parola successiva) utilizzano le parole per arricchire il loro mondo o la rappresentazione del mondo utilizzando le informazioni fornite durante l'addestramento. Per citare la metafora platonica dell'uomo nella caverna, in questo momento storico probabilmente sia gli esseri umani, sia i modelli LLM, si trovano in due caverne adiacenti. Al centro il mondo e la sua realtà, invisibile ad entrambi. Da entrambe le parti vengono proiettate delle forme da interpretare. Gli umani devono interpretare le forme delle AI, mentre le AI quelle degli umani. Al momento non abbiamo ancora uno o più strumenti atti ad analizzare esattamente il ragionamento dei modelli, così come non abbiamo uno strumento adeguato per comprendere il ragionamento umano.

Qualsiasi proposta, in questo momento, è solo una parte della spiegazione neanche tanto veritiera in quanto non abbiamo modo di confermare o smentire le deduzioni a cui arriviamo.

La differenza tra umani e modelli LLM non è così lontana, in neurofisiologia sappiamo estrapolare e tracciare i percorsi di un impulso elettrico dalla corteccia motoria fino al movimento del muscolo, ma non abbiamo ancora identificato cosa succede quando riceviamo una domanda e diamo una risposta. Ci sono teorie adeguate a spiegare molto bene questo processo, ma non abbiamo la certezza della sua veridicità. La mechanistic interpretability così come la neurologia cerca di scoprire quali sono i reali meccanismi interni per cui da uno stimolo abbiamo una risposta.

I modelli linguistici possiedono una conoscenza proposizionale corretta (Knowing-That o sapere che. Associa MOUSE a countryside, whiskers, Mickey, lab) e la esibisce ripetutamente nella catena di pensiero. Tuttavia, manca della competenza procedurale e del controllo metacognitivo (Knowing-How o sapere come) necessari per governare il processo di convergenza logica, arrestare la ricerca di alternative inutili e validare l'intuizione corretta. Questa dissociazione suggerisce come l'aggiunta di mera capacità di calcolo o di token non equivale automaticamente all'acquisizione di un'autentica razionalità procedurale.

Una risposta univoca sul modello più performante dell'intero spettro analizzato non è facile da fornire. L'autore ammette di avere preferenze verso alcuni modelli, dovute anche al loro utilizzo quotidiano al di fuori di questo esperimento. Bias e preferenze personali sono presenti in questa decisione, e va detto onestamente. Tenendo conto di questo limite, nel complesso il modello più convincente per l'autore, considerando le risposte adeguate e pochi errori di ragionamento evidenti nei casi osservati, è *Claude Opus 5* indicandolo come il modello con le prestazioni più soddisfacenti tra quelli considerati.

Conclusioni

Riprendendo le sei domande poste in apertura, i dati raccolti permettono una risposta a ciascuna.

RQ1/RQ2: nessun modello coincide sistematicamente con la soluzione dell'autore. Il migliore tra i modelli open-weight (*stepfun/step-3.5-flash*, 71.1%, IC 95% [61.0, 79.5]) e il migliore tra i commerciali (*x-ai/grok-4.6*, 76.7%, IC 95% [59.1, 88.2]) restano lontani dalla perfezione, e nessuno dei due è statisticamente distinguibile dagli altri modelli di vertice del proprio gruppo (McNemar+FDR: 0 coppie su 21 e su 28 rispettivamente). Includendo sinonimi validati a mano la correttezza estesa sale fino all'80.0% (*bytedance-seed/seed-2-1-turbo*): la distanza quantitativa tra modelli e soluzione di riferimento è quindi reale ma non enorme, e in parte è un artefatto delle sole metriche automatiche, non del comportamento dei modelli.

RQ3: sì, in casi specifici. Su almeno tre item (*guillo_21*, *guillo_22*, *guillo_18*) la risposta convergente dei modelli è risultata, a revisione manuale, più coerente o più naturale della soluzione originariamente scelta dall'autore. La revisione manuale integrale (100% delle righe) ha inoltre recuperato 468 sinonimi validi, le sole metriche automatiche non avrebbero mai contato tra le risposte esatte.

RQ4: la temperatura, nell'intervallo testato (0.0–0.7), non ha un effetto aggregato significativo (Cochran's $Q = 0.558$, $p = 0.757$) e il ranking dei modelli resta stabile attraverso le temperature (Spearman 0.886–0.930). Nove modelli mostrano una sensibilità individuale significativa senza correzione per confronti multipli: un segnale di flessibilità di risposta anziché di instabilità del compito.

RQ5: la dimensione del modello correla fortemente con l'accuratezza ($\rho = 0.756$ su parametri totali verificati, $\rho = 0.690$ su parametri attivi per token, $n = 45$) ma non è l'unico fattore: *gpt-oss:20b*, con soli 3.61B di parametri attivi per token, resta tra i migliori della lista, confermando come l'architettura MoE e routing abbia un peso quanto la scala grezza.

RQ6: da un punto di vista statistico questa domanda non ha una risposta univoca. Lo stesso confronto a coppie esclude un vincitore netto in RQ1/RQ2 e in questo caso è equivalente, ma la domanda chiede un giudizio qualitativo dell'autore, non una classifica. Su questo piano, il candidato ottimale è *Claude Opus 5*, per la qualità del processo anziché per l'esattezza del risultato. Il suo percorso di ragionamento su *petrichor* (*guillo_09*), l'item più difficile del dataset per rarità lessicale, procede per esclusione sistematica di alternative fino alla soluzione corretta. Non utilizza schemi patologici osservati altrove nel campione come l'iniezione di codice estraneo di *starcoder2:15b-instruct*, l'oscillazione irrisolta tra MOUSE e BEAST di *deepseek-r1:14b*, l'auto dubbio ciclico di *qwen3.5:9b* su un item già risolto correttamente. Questi casi condividono un tratto comune, il modello possiede la conoscenza proposizionale corretta (conosce esattamente la risposta), ma non il controllo procedurale per arrestarsi su di essa (non sa come fermarsi). La distinzione di Ryle tra Knowing-That e Knowing-How, discussa più avanti, descrive questo scarto meglio di un generico richiamo all'errore di ragionamento.

Al di là delle singole domande, tre risultati trasversali meritano di essere portati in chiusura. Primo, la rarità lessicale è un fattore plausibile solo per il caso isolato di *petrichor*, non un meccanismo generale di difficoltà nel dataset (Spearman $\rho = 0.246$, non significativo). Item comuni come *guillo_10* (PC) restano irrisolti quanto o più di *petrichor* perché richiedono un salto di astrazione (dal componente all'acronimo) oltre ad una parola rara. Secondo, l'introduzione del ragionamento esplicito nei modelli reasoning ha un costo computazionale correlato alla difficoltà percepita dal modello stesso, ma espone anche a nuove modalità di fallimento assenti nei modelli non-reasoning

(oscillazioni, loop, troncamenti), un semplice punteggio di accuratezza non intercetta. Terzo, la percezione umana e quella del modello della difficoltà di un item sono costrutti correlati ma non equivalenti (Kappa pesato 0.122–0.325). Il tempo di generazione racconta una storia di difficoltà vissuta dal modello diversa da quella assegnata a priori dall'autore. Il risultato invita a trattare le etichette di difficoltà dichiarate nei benchmark con cautela.

Limiti e future ricerche

Per preservare l'onestà scientifica vanno esplicitate le seguenti limitazioni metodologiche:

- Non è stato sottoposto il RAT perché se il modello fosse stato addestrato su quei dati, le risposte non sarebbero frutto di un ragionamento o associazione, ma recupero di informazioni memorizzate.
- N=1 sul giudizio di riferimento (soluzione, difficoltà, coerenza): essendo a cura dell'autore possono essere smentite. Osservazioni più approfondite sulle risposte dei modelli AI LLM comparate alla valutazione umana
- RQ4 non testa riproducibilità a parametri fissi, solo sensibilità alla temperatura
- Parametri di sampling non uniformi tra modelli commerciali per vincoli strutturali delle API/interfacce (l'API OpenAI non espone top_k)
- I modelli commerciali hanno un solo run (non 3 temperature): confrontabili con i open-weight solo su RQ1/2/3/5/6, non su RQ4

Gli approfondimenti futuri per indagare in profondità e avere una maggiore comprensione includono:

- Usare la Mechanistics Interpretability (MI) e la Explainable AI (XAI) su modelli adeguati all'estrazione dei dati
- Utilizzo di un ventaglio più ampio di temperature oltre 1
- Modifica del parametro top_P come ulteriore variabile
- Comparare le risposte del RAT con quelle di questi prompt con eventuale revisione in base ai dati ottenuti da questo esperimento iniziale
- Sottoporre gli item a valutazione umana con $N > 30$ per un risultato statistico comparabile

Bibliografia

- Ronanki K, Arvidsson, S Axell J. Prompt Engineering Guidelines for Using Large Language Models in Requirements Engineering. arXiv:2507.03405v1
- Kay, P. and Kempton, W. (1984), What Is the Sapir-Whorf Hypothesis?. American Anthropologist, 86: 65-79.
- Boroditsky, L., Schmidt, L. A., & Phillips, W. (2003). Sex, syntax, and semantics. In Language in mind: Advances in the study of language and thought. MIT Press.
- Wang C., Zhang Y., Gao L., Xu Z., Song Z., Wang Y., Chen X. Under the Shadow of Babel: How Language Shapes Reasoning in LLMs. 24327-24344. 10.18653/v1/2025.findings-emnlp.1321.
- Olteteanu AM., Hassan Zunjani F. A Visual Remote Associates Test and Its Validation. Frontiers in Psychology. 11. 10.3389/fpsyg.2020.00026.
- Ludwig Wittgenstein, Tractatus logico-philosophicus, Feltrinelli, 2022
- Ludwig Wittgenstein, Ricerche filosofiche, Einaudi, 2009
- John Rogers Searle, [Chinese room] in Intelligenza artificiale e pensiero umano. Filosofia per un tempo nuovo Castelvechi editore 2023

Appendice I

prompt_id	category	word1	word2	word3	word4	word5	solution	difficulty	meaning
guillo_01	guillotine	gluteus	adjustable	sit	office	kitchen	chair	easy	gluteus is the muscle supported, the chair is adjustable in height, the chair is in the office or in the kitchen
guillo_02	guillotine	highway	wheel	transport	fuel	insurance	car	easy	the car can ride in highway, have a wheel, and is used to transport something, need fuel to run and insurance is mandatory for a car
guillo_03	guillotine	Washington	skyscraper	sewer	courthouse	shop	city	medium	Washington is a city name, skyscraper is in the city, sewer to drain the dirty water, courthouse is in every city and shop in the city
guillo_04	guillotine	Pascal	inch	stress	cloud	blood	pressure	medium	Pascal is the unit of pressure, inch in PSI that indicate pressure for inch square, pressure of material create stress, cloud is formed from low pressure, the blood pressure
guillo_05	guillotine	moon	speed	lamp	hope	visible	light	medium	moon light, speed of the light, light of the lamp, light of the hope, visible light
guillo_06	guillotine	videogame	human	society	advance	history	civilization	medium	Civilization is a videogame, human civilization, civilized society, advance in civilization, history of the civilization
guillo_07	guillotine	Patrick	sun	wars	five	multiplication	star	medium	Patrick star character of SpongeBob, the sun is a star, Star Wars the movie, a five-star hotel, star or asterisk is used to indicate the multiplication
guillo_08	guillotine	card	dental	suspension	nose	burn	bridge	hard	Use card in bridge game, dental bridge replaces teeth, suspension bridge structure, bridge of the nose, “burn your bridges” idiom
guillo_09	guillotine	rain	arid	perfume	terrain	lift	petrichor	hard	when rain in arid terrain the perfume lifted from terrain is called petrichor
guillo_10	guillotine	CPU	RAM	GPU	HD	VRAM	PC	easy	the acronym of a component of a PC (used acronym)
guillo_11	guillotine	language	snake	colt	monty	biceps	python	medium	Python is a programming language, python is a snake, colt python 357 magnum, Monty Python, slang in body builder for biceps
guillo_12	guillotine	qualification	book	academic	noble	job	title	medium	qualification title, academic title, noble title, job title
guillo_13	guillotine	gestational	politics	court	another	substitute	surrogate	hard	gestational surrogate, a surrogate politics is a man that talk for another, another people is a surrogate of me, a substitute of me is a surrogate

guillo_14	guillotine	geometric	meditation	art	powder	sanskrit	mandala	hard	Mandala is a geometric figure, used for meditation, and a type of art using a powder to create it and is a Sanskrit word
guillo_15	guillotine	mean	math	analysis	descriptive	inferential	statistic	medium	mean is a math analysis to describe inferential conclusion in statistics
guillo_16	guillotine	aircraft	geometry	woodworking	thought	surface	plane	hard	in aviation aircraft is a plane, a geometric figure in two dimensions, in woodworking is a tool to flatten surface, in spiritual is a higher plane if thought, surface is a part of a cube
guillo_17	guillotine	cloth	rectangular	pole	symbol	signal	flag	medium	The flag is a piece of cloth generally rectangular fixed in a pole used like a symbol of a nation or a signal to signaling something
guillo_18	guillotine	game	television	bird	observe	vigilante	watching	medium	watching a sport game, watching television, bird watching, observing is an action to watch, vigilante watching the residential zone
guillo_19	guillotine	double	red	fingers	angry	necklace	cross	hard	double-cross means betray, Red Cross organization, cross your fingers for luck, cross is British slang for angry, a cross pendant on a necklace
guillo_20	guillotine	exotic	adventure	fly	culture	relax	travel	medium	travel in a exotic location, adventure travel, travel using plane and fly, travelling to know different culture, relaxing travel
guillo_21	guillotine	exit	shelves	cart	pay	customer	supermarket	medium	everything is inside a supermarket
guillo_22	guillotine	reaction	response	driven	cognitive	adrenaline	emotion	medium	An emotion reaches a reaction and a response, emotion drives our behavior, is a cognitive study, emotion activates the adrenal system
guillo_23	guillotine	philosophy	math	physics	business	society	concept	hard	Philosophy concept, math concept, physics concept, business concept, society concept
guillo_24	guillotine	construct	lamp	problem	innovation	good	idea	hard	idea is a construct, the lamp over the head when someone has an idea, idea that innovates particular field, a good idea
guillo_25	guillotine	tree	pie	computer	day	York	apple	easy	apple tree, apple pie dessert, Apple computer brand, “an apple a day” proverb, New York = the Big Apple
guillo_26	guillotine	love	Plato	essentialism	taoism	knowledge	philosophy	medium	Philosophy is the love for knowledge, essentialism is a part of philosophy, Plato as a philosopher, Taoism is a philosophy (and a religion)
guillo_27	guillotine	renewable	resource	environmental	social	economic	sustainability	hard	renewable energy is sustainability, sustainability resource, sustainability environmental, social sustainability, economic sustainability

guillo_28	guillotine	countryside	hole	whiskers	Mickey	lab	mouse	medium	mouse live in countryside in a hole, have a whisker, mickey mouse, laboratory mouse
guillo_29	guillotine	barrel	web	wood	rusty	cat	scraping	hard	scrape the bottom of the barrel, web scraping, wood scraping to abrading surface, scrape the rust from iron, cat scraping itself to clean your fur
guillo_30	guillotine	today	simple	gift	time	now	present	medium	Today is in present time, simple present a conjugation, present as a gift, present is a time, now is in the present

Appendice II

I file Python del progetto sono disponibili al seguente repository GitHub:
<https://github.com/AEONPHYTON/guillotine>